

SKRIPSI

ANALISIS SENTIMEN BERBASIS ASPEK PADA BEBEK SINJAY MENGGUNAKAN *LABEL POWERSET* DENGAN METODE *ENSEMBLE XGBOOST*



Oleh:

Dhafa Febriyan wiranata

200411100169

**Dosen Pembimbing 1 : Dr. Fika Hastarita Rachman, S.T., M.Eng.
Dosen Pembimbing 2 : Dr. Imamah, S.Kom., M.Kom**

PROGRAM STUDI TEKNIK INFORMATIKA

JURUSAN TEKNIK

UNIVERSITAS TRUNODJOYO MADURA

2026

ABSTRAK

Bebek sinjay adalah salah satu rumah makan yang telah berkembang pesat dengan berbagai cabang di Indonesia. Namun, untuk mempertahankan dan meningkatkan kepuasan pelanggan, rumah makan Bebek Sinjay perlu memperhatikan ulasan pelanggan dari Google Maps. Ulasan yang akan digunakan adalah aspek seperti makanan, pelayanan, harga, tempat yang dapat dijadikan bahan evaluasi untuk perbaikan. Penelitian ini mengusulkan penggunaan metode klasifikasi sentimen berbasis aspek menggunakan pendekatan machine learning. Pendekatan yang digunakan adalah *multi-label classification* dengan metode *XGBoost* dan label powerset. Data ulasan yang digunakan dalam penelitian ini diambil dari Rumah Makan Bebek Sinjay KM21 gedung baru. Data ulasan Bebek Sinjay Km21 yang digunakan awalnya berjumlah 2508, namun setelah proses *cleaning* untuk menghapus ulasan yang kosong, duplikat, ulasan yang tidak relevan dan yang bukan dalam bahasa Indonesia, jumlah ulasan yang digunakan berkurang menjadi 1157. Data tersebut dilakukan pelabelan aspek dan label powerset. Setelah proses pelabelan data masuk ke dalam tahap preprocessing yang meliputi *case folding*, *remove punctuation*, *tokenization*, *normalization*, *stemming* dan *stopword removal*. Setelah tahap preprocessing selesai data dilakukan pembobotan kata menggunakan TF-IDF. Setelah dilakukan pembobotan kata, data dibagi menjadi data latih dan data uji dengan perbandingan 80%:20%.

DAFTAR ISI

ABSTRAK	i
DAFTAR ISI.....	ii
DAFTAR GAMBAR.....	v
DAFTAR TABEL	vi
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	4
1.2.1 Permasalahan.....	4
1.2.2 Solusi Permasalahan.....	4
1.3 Batasan Penelitian	4
1.4 Pertanyaan Penelitian	5
1.5 Tujuan Dan Manfaat.....	5
1.5.1 Tujuan.....	5
1.5.2 Manfaat.....	5
BAB II KAJIAN PUSTAKA	6
2.1 <i>Web Scraping</i>	6
2.2 Analisis Sentimen Berbasis Aspek (ABSA).....	6
2.3 Multi-label Classification.....	7
2.4 Label <i>Powerset</i>	7
2.5 Ensemble Learning.....	8
2.6 Teknik <i>Boosting</i>	9
2.7 Extreme Gradient Boost (XGBOOST)	10
2.8 TF-IDF	14
2.9 Confusion Matrix	16
2.10 Penelitian Terdahulu	18
BAB III METODE PENELITIAN	22
3.1 Arsitektur Sistem.....	22
3.2 Pengumpulan Data	23
3.3 Cleaning Data	23
3.4 Pelabelan Data.....	24
3.5 Preprocessing	26
3.5.1 <i>Case Folding</i>	26
3.5.2 <i>Remove Punctuation</i>	27

3.5.3	<i>Tokenized</i>	27
3.5.4	Stopword Removal.....	27
3.5.5	Normalization.....	28
3.5.6	<i>Stemming</i>	28
3.6	TF-IDF	29
3.7	Split Data.....	31
3.8	Extreme Gradient Boost (XGBOOST)	31
3.8.1	Data Train.....	31
3.8.2	Data Test.....	37
3.9	Tools dan Library	40
3.9.1	Python.....	40
3.9.2	Google Colab.....	41
3.9.3	Streamlit	41
BAB IV HASIL DAN PEMBAHASAN.....		42
4.1	Pengumpulan Data	42
4.2	<i>Cleaning</i> Data.....	43
4.3	Pelabelan Data.....	44
4.4	<i>Preprocessing</i>	44
4.4.1	<i>Case Folding</i>	44
4.4.2	<i>Remove Punctuation</i>	45
4.4.3	<i>Tokenization</i>	46
4.4.4	<i>Stopword Removal</i>	47
4.4.5	<i>Normalization</i>	48
4.4.6	<i>Stemming</i>	49
4.5	Konversi Biner Multi-Label	51
4.6	TF-IDF	51
4.7	Split Data.....	53
4.8	Klasifikasi Multi-Label XGBOOST	53
4.9	Lingkungan Pengujian.....	55
4.10	Implementasi Antar Muka	55
4.11	Hasil Skenario Pengujian	56
4.12	Analisis Hasil	58
BAB V KESIMPULAN DAN SARAN		60
5.1	Kesimpulan.....	60

5.2	Saran.....	60
DAFTAR PUSTAKA.....		62

DAFTAR GAMBAR

Gambar 2.1 Klasifikasi Multi-Label	8
Gambar 2.2 Metode Ensemble Learning	9
Gambar 2.3 Teknik Boosting	10
Gambar 2.4 Struktur Algoritma XGBoost	11
Gambar 3.1 Arsitektur Sistem	22
Gambar 3.2 Distribusi Data	25
Gambar 3.3 Contoh Hasil Case Folding	26
Gambar 3.4 Contoh Hasil Remove Punctuation	27
Gambar 3.5 Contoh Hasil Tokenized	27
Gambar 3.6 Contoh Hasil Stopword Removal	28
Gambar 3.7 Contoh Hasil Normalization	28
Gambar 3.8 Contoh Hasil Stemming	29
Gambar 3.9 Proses TF-IDF	29
Gambar 3.10 Alur Perhitungan Training Xgboost	32
Gambar 3.11 Alur perhitungan data testing	38
Gambar 4.1 Pengumpulan Data	42
Gambar 4.2 Hasil dari Proses Case Folding	45
Gambar 4.3 Hasil dari Proses Remove Punctuation	46
Gambar 4.4 Hasil dari Proses Tokenization	47
Gambar 4.5 Hasil dari Proses Stopword Removal	48
Gambar 4.6 Hasil dari Proses Normalization	49
Gambar 4.7 Hasil dari Proses Stemming	50
Gambar 4.8 Hasil dari Pre Processing	51
Gambar 4.9 Tampilan Antar Muka Aplikasi	55
Gambar 4.10 Tampilan Antar Muka Aplikasi Setelah Diproses	56

DAFTAR TABEL

Tabel 2.1 Confusion Matrix	16
Tabel 2.2 Penelitian Terdahulu.....	18
Tabel 3.1 Contoh Hasil Scrapping	23
Tabel 3.2 Contoh Encode Label Powerset	24
Tabel 3.3 Contoh Pelabelan Label Powerset.....	25
Tabel 3.4 Data Label Powerset.....	26
Tabel 3.5 Hasil Perhitungan TF, DF, dan IDF	30
Tabel 3.6 Hasil Perhitungan TF-IDF	30
Tabel 3.7 Menentukan Probabilitas Awal.....	32
Tabel 3.8 Hasil Perhitungan Prediksi Awal	33
Tabel 3.9 Hasil Label One-Hot Encoding	33
Tabel 3.10 Hasil Keseluruhan Perhitungan Gradient	34
Tabel 3.11 Hasil Perhitungan Hessian.....	34
Tabel 3.12 Fitur Enak dalam TF-IDF	34
Tabel 3.13 Hasil Perhitungan Total Gain pada Tree Pertama	35
Tabel 3.14 Skenario Uji Coba	40
Tabel 4.1 Hasil Pengumpulan Dataset	43
Tabel 4.2 Hasil sampel TF-IDF	52
Tabel 4.3 Spesifikasi Perangkat	55
Tabel 4.4 Skenario Pengujian.....	56
Tabel 4.5 Parameter Skenario 1	57
Tabel 4.6 Hasil Evaluasi Skenario 1	57
Tabel 4.7 Hasil Evaluasi Skenario 2	58

BAB I

PENDAHULUAN

1.1 Latar Belakang

Dalam beberapa tahun terakhir perkembangan bisnis kuliner di Indonesia menunjukkan tren yang sangat positif, baik di wilayah perkotaan maupun pedesaan. Berbagai jenis kuliner lokal dan internasional terus bermunculan menyesuaikan dengan selera masyarakat yang beragam. Menurut data dari Badan Pusat Statistik (BPS), sektor kuliner berkontribusi sekitar 34% terhadap Produk Domestik Bruto (PDB) nasional pada tahun 2023. Selain itu, Menteri Pariwisata dan Ekonomi Kreatif, Sandiaga Uno, menyatakan bahwa subsektor kuliner, fashion, dan kriya menyumbang 75% terhadap nilai PDB ekonomi kreatif nasional pada tahun 2023. Kondisi ini menunjukkan bahwa persaingan di industri kuliner semakin ketat dan setiap pelaku usaha dituntut untuk terus berinovasi dalam meningkatkan kepuasan pelanggan. Untuk tetap bersaing dalam industri kuliner saat ini, mengadaptasi produk dengan selera pelanggan sangat penting mengingat persaingan yang ketat (Salsabillah et al., 2024a).

Bebek Sinjay adalah salah satu rumah makan legendaris yang berasal dari Pulau Madura dan telah dikenal luas di Indonesia. Dikenal dengan menu andalan nasi bebek goreng yang empuk dan gurih disertai sambal pencit yang khas. Bebek Sinjay berdiri sejak tahun 2002 yang awalnya hanyalah warung makan biasa di pinggir jalan dengan menyewa tempat kepada orang lain (Winalda & Sudarwanto, 2022). Dengan perkembangan bisnisnya, Bebek Sinjay telah membuka beberapa cabang lain di berbagai kota di Indonesia. Namun, di tengah pertumbuhan tersebut, rumah makan ini menghadapi tantangan besar dalam menjaga kualitas layanan dan makanan serta mempertahankan loyalitas pelanggan di tengah banyaknya pesaing di sektor yang sama.

Dalam era digital seperti saat ini, internet menjadi media yang sangat efektif bagi pelanggan untuk menyampaikan pendapat dan ulasan tentang suatu produk atau layanan. Pada ulasan tersebut tentunya akan ada opini muncul yang sangat beragam dan bervariasi (Zidny, 2024). Ulasan yang diberikan pelanggan dapat mempengaruhi reputasi dan citra suatu bisnis, sehingga penting bagi pelaku usaha untuk memanfaatkan data ulasan ini sebagai bahan evaluasi. Berbagai platform

seperti Google Maps, TripAdvisor, dan media sosial memungkinkan pelanggan untuk dengan mudah memberikan ulasan yang mencakup berbagai aspek seperti rasa makanan, kebersihan tempat, keramahan pelayanan, hingga harga. Salah satu metode yang dapat digunakan untuk menganalisis opini masyarakat tersebut yaitu analisis sentimen (Nitami & Februariyanti, 2022).

Analisis sentimen menjadi salah satu metode yang biasa digunakan dalam hal memahami pendapat pelanggan dari data ulasan yang tersedia di internet. Analisis sentimen juga biasa dikenal dengan opinion mining yang merupakan penelitian yang menganalisis opini publik, emosi, penilaian, sikap dan sentimen tentang suatu objek seperti organisasi, produk, layanan, individu, peristiwa, masalah dan topik (Rifa'i et al., 2021). Analisis sentimen adalah proses mengklasifikasikan opini dalam teks ke dalam kategori sentimen positif, negatif, atau netral. Namun, pendekatan analisis sentimen berbasis dokumen atau kalimat sering kali kurang efektif ketika sebuah ulasan mencakup berbagai aspek yang berbeda. Sebagai contoh, seorang pelanggan dapat memberikan ulasan positif terhadap rasa makanan tetapi memberikan ulasan negatif terhadap layanan yang diterima. Oleh karena itu, diperlukan pendekatan yang lebih mendalam, yaitu analisis sentimen berbasis aspek.

Analisis sentimen berbasis aspek (ASBA) adalah sub-bidang analisis sentimen yang berfokus pada identifikasi sentimen terhadap aspek tertentu dari suatu produk atau layanan (Firdaus et al., 2024). Analisis sentimen berbasis aspek bertujuan untuk mengidentifikasi sentimen terhadap aspek-aspek tertentu dalam sebuah ulasan. Pendekatan ini sering kali memerlukan metode *multi-label classification*, dimana sebuah ulasan dapat diklasifikasikan ke dalam lebih dari satu label sentimen. Klasifikasi multi-label sangat cocok untuk menyelesaikan permasalahan tersebut karena setiap pernyataan dapat memiliki lebih dari satu tagar yang digunakan sebagai label atau kelas (Fitriani1 & Yustanti2, 2022). Berbeda dengan *multi-class classification* yang hanya dapat memprediksi satu kelas untuk setiap sampel, *multi-label classification* memungkinkan model untuk memberikan lebih dari satu prediksi label pada satu ulasan (Luaces et al., 2012). Metode ini menjadi relevan ketika ulasan pelanggan mencakup banyak aspek dengan sentimen yang berbeda.

Dalam konteks klasifikasi multi-label, ada beberapa pendekatan yang dapat digunakan, salah satunya ialah metode *problem transformation*. Label Powerset berfungsi mengkonversi dataset multi-label ke dalam format dataset single-label melalui proses transformasi yang mengubah setiap kombinasi label unik pada data multi-label menjadi kategori terpisah dalam data single-label (Fadlilah et al., 2025). Metode ini bekerja dengan membuat satu classifier multi-class yang dilatih pada semua kombinasi label unik yang ditemukan dalam data training. Sebagai contoh, jika terdapat aspek makanan, layanan, harga, dan tempat, maka label powerset akan membentuk kombinasi seperti “makanan”, “layanan”, “makanan,layanan”, “makanan,harga”, “layanan,tempat”, dan seterusnya. Setiap kombinasi ini kemudian diperlakukan sebagai kelas terpisah dalam proses klasifikasi. Keunggulan dari metode label powerset adalah kemampuannya untuk menjaga hubungan antara aspek-aspek yang berbeda dan dapat menangani situasi dimana satu aspek mempengaruhi aspek lainnya dalam ulasan pelanggan.

Beberapa penelitian sebelumnya telah mengembangkan metode analisis sentimen berbasis aspek dengan berbagai pendekatan algoritma. Misalnya, penelitian analisis sentimen berbasis aspek dengan menggunakan Support Vector Machine dan diuji dengan *K-Fold Cross Validation* menghasilkan akurasi yang cukup baik (Firdaus et al., 2024). Penelitian terkait klasifikasi Multi label dengan membandingkan kinerja metode problem transformation KNN dan Algorithm Adaptaion KNN menghasilkan multi-label KNN dengan akurasi yang kurang baik dibandingkan dengan label powerset KNN (Fitriani1 & Yustanti2, 2022). Perbandingan metode Naïve bayes dan XGBoost dalam analisis sentimen e-commerce menghasilkan bahwa akurasi metode XGBoost lebih unggul daripada Naïve Bayes (Hendrawan et al., 2022a). Penelitian lain membandingkan metode Decision Tree, Support Vector Machine dan XGBoost dalam klasifikasi review ulasan hotel menggunakan trip advisor menghasilkan XGBoost memiliki nilai akurasi tertinggi [23].

Berdasarkan dari permasalahan yang ada, penulis ingin melakukan analisis sentimen berbasis aspek pada ulasan pelanggan Bebek Sinjay dengan pendekatan multi-label classification menggunakan metode ensemble XGBoost. Data yang digunakan dalam penelitian ini diambil dari ulasan Google Maps dan aspek yang

digunakan dalam penelitian (Salsabillah et al., 2024b) yaitu aspek makanan, layanan, harga dan tempat. Sentimen yang digunakan adalah sentimen positif dan negatif. Pemilihan aspek tersebut sejalan dengan penelitian (Mathayomchan & Taecharungroj, 2020) yang menyatakan bahwa terdapat empat atribut penting dalam evaluasi restoran, yaitu food (makanan), service (layanan), atmosphere (suasana), dan value (nilai/harga). Selain itu, aspek-aspek ini juga didukung oleh sistem penilaian yang tersedia di Google Maps, di mana pengguna diminta untuk menilai aspek makanan, layanan, dan tempat dalam memberikan ulasan mereka.

1.2 Rumusan Masalah

1.2.1 Permasalahan

Banyaknya kompetitor dalam industri kuliner menuntut rumah makan Bebek Sinjay untuk terus mempertahankan kualitas dan meningkatkan kepuasan pelanggan. Kepuasan tersebut dapat dievaluasi melalui ulasan pelanggan di platform seperti Google Maps yang mencakup berbagai aspek, seperti makanan, layanan, harga, dan tempat. Penelitian sebelumnya telah mengkaji analisis sentimen berbasis aspek dengan pendekatan *multi-label classification*, namun metode yang digunakan memiliki keterbatasan dalam optimalisasi akurasi dan efisiensi model.

1.2.2 Solusi Permasalahan

Penelitian ini menawarkan solusi berupa penerapan metode ensemble XGBoost untuk menangani tantangan yang ada pada analisis sentimen berbasis aspek. Metode ini diharapkan mampu meningkatkan akurasi dan efisiensi dalam klasifikasi sentimen pada masing-masing aspek ulasan pelanggan. Dengan memanfaatkan data ulasan dari Google Maps, model ini diharapkan dapat menghasilkan analisis yang lebih akurat dan memberikan informasi strategis yang relevan bagi rumah makan Bebek Sinjay dalam mempertahankan kualitas dan meningkatkan kepuasan pelanggan.

1.3 Batasan Penelitian

Adapun batasan masalah dari penelitian ini sebagai berikut:

1. *Dataset* yang digunakan adalah data ulasan dari pelanggan rumah makan Bebek Sinjay di Google Maps (Bebek Sinjay KM. 21 Gedung Baru, n.d.).
2. Ulasan kosong dihilangkan dari dataset.

3. Ulasan yang digunakan dalam proses klasifikasi adalah ulasan yang menggunakan bahasa Indonesia.
4. *Dataset* yang digunakan berjumlah 1157 data setelah ulasan yang kosong dihapus, data duplikat dihapus dan bahasa selain bahasa indonesia dihapus. Data yang digunakan diambil dari Bebek Sinjay KM. 21 Gedung Baru dari 16 juni 2024 sampai 16 juni 2025.
5. Aspek yang digunakan adalah aspek makanan, layanan, tempat dan harga (Salsabillah et al., 2024b).
6. Sentimen yang digunakan adalah positif dan negatif.

1.4 Pertanyaan Penelitian

Berapa nilai Hamming Loss, Precision, Recall, F1-Score yang dihasilkan dalam menganalisis sentimen berbasis aspek pada ulasan rumah makan Bebek Sinjay menggunakan multi label dengan metode ensemble XGBoost?

1.5 Tujuan Dan Manfaat

1.5.1 Tujuan

Berdasarkan rumusan masalah dan tujuan diatas, maka manfaat dari penelitian ini adalah

1. Mengembangkan model analisis sentimen berbasis aspek menggunakan *multi-label* dengan metode Ensemble XGBoost untuk ulasan rumah makan bebek sinjay.

1.5.2 Manfaat

1. Meningkatkan kualitas layanan serta memahami kebutuhan dan harapan pelanggan rumah makan Bebek Sinjay.
2. Menjadi referensi dalam pengembangan metode analisis sentimen berbasis aspek.

BAB II

KAJIAN PUSTAKA

2.1 *Web Scraping*

Web scraping adalah metode untuk mengekstraksi informasi dari halaman web yang tidak terstruktur dan mengubahnya menjadi data terstruktur seperti spreadsheet, basis data, atau file CSV. Proses ini dimulai dengan menentukan halaman web yang relevan sebagai sumber data, diikuti dengan langkah ekstraksi elemen-elemen data yang diperlukan. *Web scraping* memungkinkan pengumpulan data secara otomatis dan dapat dianalisis dan dimanfaatkan untuk berbagai tujuan (Mufidah, 2022).

Web scraping digunakan untuk mengumpulkan ulasan terkait Bebek Sinjay dari platform *Google Maps*. Proses ini melibatkan identifikasi elemen data penting seperti teks ulasan dan rating, diikuti dengan pembersihan dan transformasi data untuk mempersiapkan data mentah menjadi siap dianalisis. Alat yang digunakan dalam proses ini adalah *Instant Data Scraper*, sebuah ekstensi browser yang dirancang untuk melakukan ekstraksi data secara efisien.

2.2 Analisis Sentimen Berbasis Aspek (ABSA)

Analisis sentimen berbasis aspek adalah bagian dari bidang ilmu yang terkait dengan penambahan teks, pemrosesan bahasa alami, dan kecerdasan buatan. Dengan analisis sentimen, data teks dapat diolah menjadi informasi yang berguna secara otomatis (Radiena & Nugroho, 2023). Data teks yang berhasil terkumpul dianalisis untuk mendapatkan kesimpulan berupa sentimen positif, negatif, maupun netral. Analisis sentimen dapat diterapkan pada level dokumen, kalimat, dan aspek (Morama et al., 2022). Analisis sentimen berbasis aspek merupakan pendekatan yang digunakan untuk mengetahui pendapat dari pengguna mengenai aspek apa yang disukai dan tidak disukai. Pendekatan berbasis aspek ini adalah solusi untuk menangani masalah analisis sentimen yang sebelumnya hanya melakukan klasifikasi sentimen ke kelas positif atau negatif tanpa mempertimbangkan kategori aspek. Analisis sentimen berbasis aspek berperan dalam melakukan klasifikasi ulasan ke kelas positif atau negatif berdasarkan aspek yang relevan.

Model yang dihasilkan dari analisis ini mampu mengklasifikasikan sebuah dokumen teks ke dalam kategori aspek tertentu serta menentukan polaritas sentimen

dari aspek tersebut. Sebagai contoh, pada kalimat ulasan "Makanannya enak tapi harganya cukup mahal," model analisis sentimen berbasis aspek dapat mengklasifikasikan kalimat tersebut ke dalam aspek "makanan" dengan polaritas sentimen positif dan aspek "harga" dengan polaritas sentimen negatif. Pengetahuan mengenai aspek dan sentimennya dapat membantu meningkatkan kualitas layanan sesuai dengan umpan balik yang diberikan pengguna (Naquitasia et al., 2022).

2.3 *Multi-label Classification*

Multi-label classification adalah metode pembelajaran mesin yang digunakan untuk mengatasi masalah di mana satu sampel data dapat memiliki lebih dari satu label atau kategori. Berbeda dengan klasifikasi tradisional (*single-label classification*) yang hanya memetakan setiap sampel ke satu label, klasifikasi multi-label memungkinkan satu sampel memiliki beberapa label yang relevan. Contohnya adalah analisis ulasan pelanggan, di mana sebuah ulasan dapat mencakup beberapa aspek seperti makanan, harga, dan pelayanan sekaligus, masing-masing dengan sentimen yang berbeda.

Dalam *multi-label classification*, setiap kelas direpresentasikan dalam bentuk biner, di mana nilai 1 menunjukkan keberadaan label dan nilai 0 menunjukkan ketiadaan label. Dengan demikian, satu data dapat memiliki lebih dari satu label secara bersamaan..

Pada penelitian ini, permasalahan multi-label tidak diselesaikan secara langsung, melainkan menggunakan pendekatan Label Powerset yang mengubah kombinasi beberapa label menjadi satu label tunggal. Dengan pendekatan ini, permasalahan multi-label diubah menjadi klasifikasi multiclass, sehingga setiap data hanya memiliki satu label yang merepresentasikan kombinasi dari beberapa label sebelumnya.

2.4 *Label Powerset*

Label Powerset adalah salah satu metode transformasi dalam multi-label classification yang mengubah permasalahan multi-label menjadi permasalahan single-label. Label Powerset mengubah langsung kumpulan data multi-label menjadi kumpulan data single-label dengan cara mentransformasikan setiap kombinasi label yang unik dalam data multi-label menjadi sebuah kelas yang berbeda dalam data single-label (Fadlilah et al., 2025).



X	Y1	Y2	Y3
X1	1	0	0
X2	0	1	1
X3	0	0	1
X4	0	1	1
X5	1	0	0


X	Class
X1	1
X2	2
X3	3
X4	2
X5	1

Gambar 2.1 Klasifikasi Multi-Label (Novanza et al., 2025)

Gambar 2.1 menjelaskan proses transformasi pada data multi-label yang memiliki tiga label target (Y1, Y2, dan Y3), setiap baris data memiliki kombinasi label tertentu, seperti [1, 0, 0], [0, 1, 1], atau [0, 0, 1]. Kombinasi tersebut kemudian direpresentasikan sebagai satu kelas tunggal, misalnya Class 1 untuk [1, 0, 0], Class 2 untuk [0, 1, 1], dan Class 3 untuk [0, 0, 1]. Keunggulan utama dalam label powerset adalah mempertahankan korelasi antar label yang kompleks (Novanza et al., 2025). Berbeda dengan pendekatan klasifikasi biner tradisional yang hanya mempertimbangkan hubungan positif dan negatif untuk setiap label nya. Label powerset mampu mempertahankan hubungan dan korelasi antar semua label dalam satu kombinasi.

2.5 *Ensemble Learning*

Ensemble learning adalah metode machine learning yang menggabungkan beberapa model untuk meningkatkan hasil prediksi dibandingkan dengan menggunakan model tunggal. Dengan menggunakan dua atau lebih model sistem dapat belajar dari berbagai sumber data dan membuat prediksi lebih akurat, tepat dan kuat karena satu model bisa mengoreksi model lainnya (Sondakh et al., 2023). Metode ini bertujuan untuk meningkatkan keakuratan dan keandalan dalam memprediksi hasil dengan cara mereduksi underfitting, overfitting atau meningkatkan prediksi pada data yang bervariasi.




Gambar 2.2 Metode Ensemble Learning (*Ensemble Learning: Bagging & Boosting, n.d.*)

Gambar 2.2 menunjukkan dua kategori utama dalam ensemble learning yaitu metode bagging dan metode boosting. Metode Bagging bekerja dengan cara membuat beberapa model dari subset data yang berbeda dan menggabungkan hasilnya, sementara boosting secara iteratif meningkatkan model dengan memprioritaskan data yang sulit diklasifikasikan. Teknik ensemble sering digunakan dalam berbagai aplikasi karena dapat meningkatkan akurasi dan robustitas prediksi dengan mengurangi risiko overfitting pada data pelatihan.

2.6 Teknik *Boosting*

Boosting adalah salah satu metode ensemble learning yang memiliki tujuan dalam peningkatan performa model dengan cara membangun rangkaian model secara berurutan. Ada beberapa macam metode dalam boosting yaitu Adaptive Boosting (Adaboost), Extreme Gradient Boosting (XGBoost), Light Gradient Boosting Machine (LightGBM), dan Categorical Boosting (CatBoost).




Gambar 2.3 Teknik *Boosting* (*Boosting in Machine Learning, n.d.*)

Gambar 2.3 menjelaskan dalam boosting dimana proses dimulai dengan melatih model pertama pada dataset asli dan nantinya akan menemukan kesalahan klasifikasi dalam data. Pada iterasi berikutnya, data yang salah diklasifikasikan oleh model sebelumnya diberikan bobot lebih besar, sehingga model selanjutnya lebih fokus pada data yang sulit diprediksi. Proses ini akan terus berulang hingga beberapa iterasi dengan setiap model memperbaiki kesalahan dari model sebelumnya secara bertahap. Pada langkah terakhir, semua model digabungkan menggunakan metode agregasi seperti voting atau weighted average untuk menghasilkan prediksi akhir yang lebih akurat. Teknik ini sangat baik untuk menangani data kompleks atau tidak seimbang. Namun, jika terlalu berfokus pada noise dalam data atau jika parameter model tidak diatur dengan baik, teknik ini dapat menghasilkan overfitting. Teknik boosting melatih model lemah (weak learner), menghitung prediksi, memilih sampel yang tidak sesuai, melatih proses lainnya dengan sampel yang salah dari iterasi sebelumnya (Rama Hadi Suryanto & Wahyu Utomo, 2024). Hasil akhirnya adalah meningkatkan pembelajar lemah dengan bias tinggi menjadi model yang lebih kompleks dan akurat.

2.7 Extreme Gradient Boost (XGBOOST)

Extreme Gradient Boosting (XGBoost) adalah metode dari *machine learning* yang menggabungkan beberapa model *Decision Tree* untuk memperbaiki kesalahan pohon sebelumnya secara iteratif (Aliefia & Irawan, 2025). XGBoost dapat

digunakan untuk berbagai tugas *supervised learning* seperti klasifikasi, regresi dan ranking karena metode ini sangat efektif dalam menangani dataset yang besar (Duman, 2022). Berbeda dengan LightGBM memiliki kecepatan dalam pelatihan namun rentan dalam *overfitting*, serta CatBoost yang memiliki performa luar biasa dalam dataset kategori namun lemah dalam fitur numerik (*XGBoost vs LightGBM vs CatBoost Perbandingan Terbaik (2025)*, n.d.). Algoritma XGBoost dirancang untuk efisiensi komputasi, akurasi, dan fleksibilitas dalam menangani berbagai jenis data. XGBoost juga merupakan versi lebih efisien dan 10 kali lebih cepat dibanding metode Gradient Boosting, karena menggunakan teknik regulasi dan pemrosesan paralel untuk meningkatkan efisiensi serta akurasi (Erkamim et al., 2024) (Septiana Rizky et al., 2022). Fitur utama XGBoost adalah kemampuannya untuk memproses data yang tidak seimbang (*overfitting*) melalui penyesuaian bobot, serta integrasi pengaturan parameter yang memungkinkan pengguna untuk mengontrol kompleksitas model. Gambar 2.3 merupakan alur dari metode XGBoost.



Gambar 2.4 Struktur Algoritma XGBoost (*Simplified Structure of XGBoost, n.d.*)

Pada saat proses klasifikasi, XGBoost akan memperbarui bobot pada setiap pohon yang dibangun sehingga dihasilkan model klasifikasi yang lebih kuat [20]. Selanjutnya, seluruh bobot pohon dijumlahkan saat melakukan prediksi, lalu dimasukkan ke dalam fungsi logistik. Keunggulan utama XGBoost meliputi efisiensi komputasi, kemampuan menangani data yang hilang, serta kemampuannya dalam mengurangi kesalahan bias dan varians. Hal ini

menunjukkan bahwa XGBoost unggul dalam menangani proses klasifikasi. Perhitungan XGBoost dapat dilakukan sebagai berikut:

1. Menentukan nilai awal prediksi

Pada tahap awal, nilai skor untuk setiap kelas diinisialisasi dengan nilai nol karena model belum belajar dari proses pelatihan (2.1).

$$a_k = 0 \quad (2.1)$$

Keterangan:

a_k = skor awal

k = indeks kelas

2. Menghitung probabilitas awal

Mengubah skor awal menjadi probabilitas menggunakan persamaan (2.2).

$$p(C_k | \phi) = \frac{\exp(a_k)}{\sum_j \exp(a_j)} \quad (2.2)$$

Keterangan:

$p(C_k | \phi)$ = nilai probabilitas awal

$\exp(a_k)$ = nilai eksponensial dari kelas k

$\sum_{j=1}^K \exp(a_j)$ = jumlah eksponensial dari semua kelas

Nilai ini digunakan untuk menghasilkan prediksi awal model.

3. One Hot Encoding

One-hot encoding berguna untuk menampilkan label dalam bentuk numerik.

Dalam kasus di mana label memiliki banyak kategori, setiap kategori diwakili dengan vektor biner.

4. Perhitungan Gradient

Gradient dihitung dengan menggunakan persamaan (2.3).

$$g_k = p_k - y_k \quad (2.3)$$

Keterangan :

g_k = nilai gradient

p_k = nilai probabilitas awal

y_k = nilai label pada one-hot encoding

Gradient merupakan turunan pertama dari fungsi loss terhadap prediksi model, yang menampilkan arah perubahan untuk meminimalkan kesalahan.

5. Hessian dihitung dengan menggunakan persamaan (2.4).

$$h_k = p_k(1 - p_k) \quad (2.4)$$

Keterangan:

h_k = nilai hessian

p_k = nilai probabilitas awal

Hessian adalah turunan kedua yang menunjukkan tingkat perubahan dari gradient, yang membantu dalam menentukan ukuran langkah pembaruan model.

6. Perhitungan Gain

Setelah menghitung gradient dan hessian tahap selanjutnya adalah melakukan perhitungan dengan information gain menggunakan persamaan (2.5) yang berfungsi untuk menentukan split terbaik dari semua fitur.

$$Gain = \frac{1}{2} \left[\frac{G_{kiri}^2}{H_{kiri} + \lambda} + \frac{G_{kanan}^2}{H_{kanan} + \lambda} - \frac{(G_{kiri} + G_{kanan})^2}{H_{kiri} + H_{kanan} + \lambda} \right] - \gamma \quad (2.5)$$

Keterangan:

G_{kiri} = nilai gradient kiri

G_{kanan} = nilai gradient kanan

H_{kiri} = nilai gradient kiri

H_{kanan} = nilai gradient kanan

γ = nilai gamma

λ = nilai gamma

Dari semua fitur yang sudah dihitung nilai gain yang memiliki nilai tertinggi yang dipilih untuk di proses pada tahap selanjutnya

7. Menghitung bobot

Digunakan untuk menentukan bobot optimal pada setiap leaf node menggunakan gradient dan hessian menggunakan persamaan (2.6).

$$w_j^* = - \frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda} \quad (2.6)$$

Keterangan:

w_j^* = nilai bobot

g_i = nilai gradient
 h_i = nilai hessian
 λ = lambda

8. Update prediksi

Proses selanjutnya adalah update prediksi menggunakan persamaan (2.7) dimana setelah prediksi telah dilakukan maka nilainya akan digunakan dalam tree selanjutnya sebagai prediksi awal.

$$F_k^{(t)}(x_i) = F_k^{(t-1)}(x_i) + \eta w_{q(x_i),k} \quad (2.7)$$

Keterangan:

$F_k^{(t)}(x_i)$ = nilai prediksi baru
 $F_k^{(t-1)}(x_i)$ = prediksi awal
 η = *learning rate*
 $w_{q(x_i),k}$ = nilai bobot

Lakukan langkah nomor 3 sampai 9 untuk membuat iterasi baru.

9. Menghitung prediksi akhir menggunakan persamaan (2.8)

$$\hat{y}_i = \phi(x_i) = \sum_{k=1}^K f_k(x_i), f_k \in F \quad (2.8)$$

Keterangan:

$\hat{y}_i$ = prediksi akhir
 K = jumlah total pohon

Prediksi akhir diperoleh dengan menjumlahkan kontribusi dari seluruh tree sehingga menghasilkan skor logit. Nilai tersebut kemudian dikonversi menjadi probabilitas menggunakan fungsi softmax, dan kelas dengan probabilitas tertinggi dipilih menggunakan fungsi argmax sebagai hasil akhir prediksi.

2.8 TF-IDF

TF-IDF (Term Frequency-Inverse Document Frequency) adalah sebuah cara yang biasa digunakan dalam pengolahan teks untuk mengukur kepentingan sebuah kata dalam sebuah dokumen relatif terhadap kumpulan dokumen (corpus). Teknik ini diaplikasikan untuk menghitung jumlah kemunculan kata dalam sebuah dokumen, lalu mengubah kata tersebut ke dalam bentuk angka yang dapat dianalisis

oleh algoritma pembelajaran mesin (Zidny, 2024). Perhitungan TF-IDF dapat dilakukan menggunakan persamaan (2.11) sebagai berikut: (*Analisis Sentimen Berbasis Aspek Pada Ulasan Pengguna Aplikasi Dompot Digital Menggunakan Metode Multinomial Naïve Bayes Skripsi Oleh: Hikmatul Maulidia Putri Nim. 200605110078 Program Studi Teknik Informatika Fakultas Sains Dan Teknologi Universitas Islam Negeri Maulana Malik Ibrahim Malang 2024, n.d.*)

$$tf(t, d) = \frac{n_{\{i,j\}}}{\sum_{k=0}^n n_{ij}} \quad (2.3)$$

Keterangan:

$tf(t, d)$: Frekuensi Kata

$n_{\{i,j\}}$: Jumlah suatu kata (i) yang muncul dalam suatu dokumen (j)

$\sum_{k=0}^n n_{i,j}$: Total seluruh kata dalam dokumen

Kemudian tahap perhitungan TF atau frekuensi kata setiap kalimat, tahap selanjutnya adalah perhitungan IDF menggunakan persamaan (2.12) (*Analisis Sentimen Berbasis Aspek Pada Ulasan Pengguna Aplikasi Dompot Digital Menggunakan Metode Multinomial Naïve Bayes Skripsi Oleh: Hikmatul Maulidia Putri Nim. 200605110078 Program Studi Teknik Informatika Fakultas Sains Dan Teknologi Universitas Islam Negeri Maulana Malik Ibrahim Malang 2024, n.d.*).

$$idf(t) = \log\left(\frac{|D|}{df_t}\right) \quad (2.4)$$

Keterangan:

$idf(t)$: Frekuensi kemunculan kata t pada seluruh dokumen

$|D|$: Total dokumen secara keseluruhan

df_t : Jumlah dokumen yang mengandung kaat t

Setelah melakukan perhitungan TF dan IDF, tahap selanjutnya adalah melakukan perhitungan nilai bobot TF-IDF menggunakan persamaan(2.13) untuk menentukan tingkat kepentingan suatu kata dalam sebuah dokumen (*Analisis Sentimen Berbasis Aspek Pada Ulasan Pengguna Aplikasi Dompot Digital Menggunakan Metode Multinomial Naïve Bayes Skripsi Oleh: Hikmatul Maulidia*

Putri Nim. 200605110078 Program Studi Teknik Informatika Fakultas Sains Dan Teknologi Universitas Islam Negeri Maulana Malik Ibrahim Malang 2024, n.d.).

$$W_{t,d} = tf_{(t,d)} \times idf_{(t)} \quad (2.5)$$

Keterangan

$W_{\{t,d\}}$: Bobot kata dalam suatu dokumen

$tf_{\{(t,d)\}}$: Frekuensi kata

$idf_{\{(t)\}}$: Frekuensi kemunculan kata t pada seluruh dokumen

2.9 Confusion Matrix

Confusion matrix digunakan untuk mengevaluasi kinerja model klasifikasi dengan memberikan gambaran yang jelas tentang seberapa baik model melakukan prediksi pada setiap kelas target. Matriks ini menunjukkan jumlah prediksi yang benar dan salah untuk setiap kelas yang diprediksi oleh model. Pada tabel 2.1 menunjukkan penjelasan tentang *confusion matrix*.

Tabel 2.1 Confusion Matrix

	Prediksi Positif	Prediksi Negatif
Aktual Positif	TP	FN
Aktual Negatif	FP	TN

TP (True Positive) terjadi ketika model berhasil mengidentifikasi kelas positif dengan benar, sementara FP (False Positive) terjadi ketika model keliru mengidentifikasi kelas positif. FN (False Negative) adalah kondisi model keliru mengklasifikasikan kelas negatif, sedangkan TN (True Negative) adalah kondisi model berhasil mengidentifikasi kelas negatif dengan benar (Nitami & Februariyanti, 2022).

Dalam penelitian ini digunakan pendekatan Label Powerset yang mengubah permasalahan multi-label menjadi klasifikasi multiclass. Oleh karena itu, evaluasi kinerja model dapat menggunakan confusion matrix multiclass. Metrik yang digunakan meliputi hamming loss, precision, recall, dan F1-score. Perhitungan precision, recall, dan F1-score dilakukan untuk setiap kelas menggunakan pendekatan one-vs-all, kemudian dirata-ratakan menggunakan macro average.

- Hamming Loss merupakan perbandingan antara jumlah prediksi yang salah terhadap seluruh data yang diuji. Metrik ini digunakan untuk mengukur tingkat kesalahan model dalam melakukan klasifikasi. Semakin kecil nilai maka semakin baik performa model.

$$Hamming Loss = \frac{1}{m} \sum_{i=1}^m I(y_i \neq h(x_i)) \quad (2.6)$$

Keterangan:

m = jumlah semua data

$I(y_i \neq h(x_i))$ = jumlah prediksi salah

- precision adalah perbandingan antara jumlah prediksi benar pada suatu kelas terhadap seluruh data yang diprediksi sebagai kelas tersebut. Metrik ini digunakan untuk mengukur tingkat ketepatan model dalam memberikan label pada suatu kelas.

$$Precision_i = \frac{TP_i}{TP_i + FP_i} \quad (2.7)$$

$$Precision_{macro} = \frac{1}{k} \sum_{i=1}^k Precision_i \quad (2.8)$$

Keterangan:

TP_i = jumlah data benar

FP_i = jumlah data salah yang diprediksi sebagai kelas tersebut

k = jumlah kelas

- Recall adalah perbandingan antara jumlah prediksi benar pada suatu kelas terhadap seluruh data yang sebenarnya termasuk dalam kelas tersebut. Metrik ini menggambarkan kemampuan model dalam menemukan kembali seluruh data yang relevan.

$$Recall_i = \frac{TP_i}{TP_i + FN_i} \quad (2.9)$$

$$Recall_{macro} = \frac{1}{k} \sum_{i=1}^k Recall_i \quad (2.10)$$

Keterangan:

TP_i = jumlah data benar

FN_i = jumlah data yang seharusnya benar tetapi tidak terprediksi

k = jumlah kelas

- F1-Score merupakan rata-rata dari precision dan recall yang digunakan untuk menyeimbangkan kedua metrik tersebut. Nilai F1-score memberikan gambaran performa model secara keseluruhan dalam hal ketepatan dan kelengkapan prediksi.

$$F1_i = 2 \cdot \frac{Precision_i \cdot Recall_i}{Precision_i + Recall_i} \quad (2.11)$$

$$F1_{macro} = 2 \cdot \frac{Precision_{macro} \cdot Recall_{macro}}{Precision_{macro} + Recall_{macro}} \quad (2.12)$$

2.10 Penelitian Terdahulu

Bagian ini membahas penelitian-penelitian sebelumnya. Penelitian terkait yang telah dilakukan sebelumnya pada Tabel 2.2 menampilkan beberapa penelitian terkait.

Tabel 2.2 Penelitian Terdahulu

NO	Nama dan Tahun	Metode	Hasil
1	Rama Hadi Suryanto & Wahyu Utomo, 2024(Rama Hadi Suryanto & Wahyu Utomo, 2024)	Ensemble Learning Boosting	Penelitian ini mengkaji Klasifikasi ulasan pengguna dengan menggunakan perbandingan teknik boosting yaitu AdaBoost, XGBoost, Gradient Boosting dan LightGBM. Dataset didapatkan dari kaggle dengan jumlah 9976 data dan menghasilkan tingkat akurasi yang cukup baik diantaranya XGBoost 92,30%, AdaBoost 83,34%, Gradient Boosting 91,68%. Dan LightGB 91,56%. Hasil akhir menunjukkan teknik boosting dengan menggunakan metode

NO	Nama dan Tahun	Metode	Hasil
			XGBoost menghasilkan performa yang baik untuk proses klasifikasi.
2	Sepbriant, G. D., & Utomo, D. W. (2024)(Dwigi Sepbriant & Utomo, 2024)	XGBoost	Penelitian ini melakukan kategorisasi dengan menggunakan teknik Boosting. Hasil dari pengujian yang dilakukan pertama kali menunjukkan bahwa <code>n_estimator</code> : 100, <code>learning_rate</code> : 0,2 dan <code>max_depth</code> : 7 diperoleh akurasi sebesar 93,41%. Sedangkan pengujian kedua dengan nilai <code>n_estimator</code> : 200, pengujian dilakukan <code>n_estimator</code> : 200, <code>learning_rate</code> : 0,2 dan <code>max_depth</code> : 7 diperoleh akurasi tertinggi sebesar 97,17%.
3	Givari, M. R., Sulaeman, M. R., & Umaidah, Y. (2022)(Givari et al., 2022)	Support Vector Machine, Random Forest, Dan XGBoost	Penelitian ini mengkaji tentang perbandingan performa algoritma SVM, Random Forest dan XGBoost dalam penentuan pengajuan kredit dimana dataset yang digunakan dari website opensource kaggle yang mempunyai jumlah fitur 20. Dataset dibagi menjadi 2 skenario yaitu 80% training dan 20% testing dan ditambahkan

NO	Nama dan Tahun	Metode	Hasil
			dengan teknik SMOTE. Hasil akhir perbandingan nya yaitu SVM 69%, Random Forest 71% dan XGBoost 82%.
4	Hendrawan, I. R., Utami, E., & Hartanto, A. D. (2022)(Hendrawan et al., 2022b)	Naïve Bayes dan XGBoost	Penelitian ini mengkaji tentang perbandingan antara metode Naïve Bayes dan XGBoost dalam klasifikasi ulasan. Data yang digunakan sebanyak 25.581 dan dibagi menjadi 2 kategori yaitu 80% training dan 20% testing. Hasil akhir akurasi menunjukkan XGBoost+TFIDF 89.2% , XGBoost+Word2vec 89.3% dan NB+TFIDF 88.7%, NB+Word2vec 83.3%.
5	Tao, J., & Fang, X. (2020) (Tao & Fang, 2020)	Transfer Learning	Penelitian ini pendekatan berbasis transfer learning untuk meningkatkan analisis sentimen multi-label, khususnya dalam konteks Aspect Based Sentiment Analysis (ABSA) dan Aspect Enhanced Sentiment Analysis (AESAs). Dengan memanfaatkan model-model transfer learning terkini seperti BERT dan XLNet, penelitian ini menunjukkan bahwa pendekatan yang diusulkan tidak hanya mampu mengatasi keterbatasan metode ABSA yang ada, tetapi juga


NO	Nama dan Tahun	Metode	Hasil
			dapat mengklasifikasikan sentimen pada tingkat dokumen dengan mempertimbangkan aspek-aspek entitas yang relevan. Hasil akhir yang dilakukan pada tiga dataset menunjukkan bahwa model yang diajukan lebih unggul dari model baseline dalam hal akurasi, Hamming loss, serta skor F1 makro dan mikro.

BAB III

METODE PENELITIAN

3.1 Arsitektur Sistem

Dalam tahap ini akan menjelaskan tentang tahapan yang akan dilakukan mulai dari awal penelitian sampai akhir penelitian tentang analisis sentimen berbasis aspek pada ulasan Bebek Sinjay menggunakan *Multi-label* menggunakan metode XGBoost. Berikut Gambar 3.1 menunjukkan struktur sistem yang akan digunakan dalam penelitian ini.



Gambar 3.1 Arsitektur Sistem

Berdasarkan gambar 3.1 dijelaskan bahwa tahap awal dimulai dari pengambilan data ulasan pelanggan rumah makan Bebek Sinjay menggunakan ekstensi dari *web scraper* yaitu Instant Data Scraper. Setelah dataset sudah didapatkan, kemudian dilakukan *cleaning data* untuk menghilangkan ulasan yang kosong lalu langkah berikutnya adalah pelabelan manual secara biner pada dataset dengan label aspek dan sentimen dan dilakukan validasi oleh pakar. Setelah itu dilakukan proses *preprocessing* data dengan melakukan *case folding*, *remove punctuation*, *tokenization*, *normalization*, *stemming*, dan *stopword removal*.

Setelah melakukan *preprocessing* data tahap berikutnya adalah melakukan pembobotan kata menggunakan TF-IDF. Setelah melakukan TF-IDF data di split menjadi data test dan data training . Hasil dari proses TF-IDF akan berbentuk matrix dan akan digunakan sebagai input pada proses klasifikasi. Proses klasifikasi akan dilakukan dengan multi-label menggunakan MultiOutputClassifier dan Extreme Gradient Boost (XGBoost) dan hasil akhirnya akan memperoleh confusion matriks yang berisi hasil *hamming loss*, *Precision*, *Recall* dan *f1-Score*.

3.2 Pengumpulan Data

Data yang digunakan dalam penelitian ini didapatkan dari ulasan rumah makan Bebek Sinjay melalui Google Maps. Proses pengumpulan data dilakukan dengan metode web scraping menggunakan ekstensi Chrome bernama Instant Data Scraper. Ulasan yang digunakan berasal dari rumah makan Bebek Sinjay KM. 21 Gedung Baru (*Bebek Sinjay KM. 21 Gedung Baru*, n.d.). Lokasi dari Rumah Makan Bebek Sinjay KM. 21 Gedung Baru beralamat di Jl. Raya Ketengan No.Km.21, Junok, Tunjung, Kec. Burneh, Kabupaten Bangkalan. Ulasan dari rumah makan Bebek Sinjay KM. 21 Gedung Baru menghasilkan sebanyak 2508 data ulasan yang dikumpulkan dari tanggal 16 April 2023 hingga 16 Januari 2025. Data hasil pengumpulan ini disimpan dalam dua format file, yaitu Excel (.xlsx) dan Comma Separated Values (CSV). Tabel 3.1 menampilkan beberapa contoh data awal dari hasil scraping.

Tabel 3.1 Contoh Hasil *Scrapping*

Nama	Waktu	Ulasan
Nur Paws	7 jam lalu	Mantap dengan suasananya yg bikin tenang
Dafinia	12 jam lalu	Makanannya enak, cabang ini termasuk yang cukup luas
khusni mustaqim	1 hari lalu	Enak bebek nya
Stay learn	2 hari lalu	Rasanya biasa saja...
arif effendi	seminggu lalu	Bebeknya mantap... Pelayanan cepat...

3.3 Cleaning Data

Pada tahap cleaning data, langkah pertama yang dilakukan adalah mengidentifikasi dan mengatasi masalah yang ada dalam dataset, seperti data yang tidak relevan, duplikat, atau kesalahan yang terjadi saat pengumpulan data. Proses ini bertujuan untuk memastikan bahwa dataset yang digunakan untuk analisis sudah

bersih dan dapat menghasilkan hasil yang akurat. Data yang awalnya berjumlah 2510 ulasan setelah dilakukan proses cleaning data menjadi 1197 ulasan.

3.4 Pelabelan Data

Pelabelan data dalam analisis sentimen ini memiliki 65 kombinasi label powerset. Pelabelan aspek mengacu pada kategori opini dalam ulasan, yaitu makanan, pelayanan, tempat, dan harga. Pelabelan sentimen menggunakan Label Powerset untuk mengubah klasifikasi multi-label menjadi single-label dengan tetap mempertahankan korelasi antar label. Sebelum dilakukan transformasi ke label powerset, setiap kombinasi label terlebih dahulu direpresentasikan dalam bentuk encode label, yaitu representasi biner yang menunjukkan kombinasi aspek dan sentimen yang muncul dalam satu ulasan. Contoh encode label dapat dilihat pada Tabel 3.2.

Tabel 3.2 Contoh Encode *Label Powerset*


Label	Encode Label
makanan positif	0_0_0_1_0_0_0_0
makanan negatif	0_0_1_0_0_0_0_0
pelayanan positif	0_0_0_0_0_1_0_0
pelayanan negatif	0_0_0_0_1_0_0_0
tempat positif	0_0_0_0_0_0_0_1
tempat negatif	0_0_0_0_0_0_1_0
harga positif	0_1_0_0_0_0_0_0
harga negatif	1_0_0_0_0_0_0_0
makanan positif,pelayanan positif	0_0_0_1_0_1_0_0
makanan positif,pelayanan negatif	0_0_0_1_1_0_0_0
makanan positif,tempat positif	0_0_0_1_0_0_0_1
makanan positif,tempat negatif	0_0_0_1_0_0_1_0
makanan positif,harga positif	0_1_0_1_0_0_0_0
makanan positif,harga negatif	1_0_0_1_0_0_0_0
makanan negatif,pelayanan negatif	0_0_1_0_1_0_0_0

Setiap kombinasi encode label yang unik kemudian dikonversi menjadi satu nilai label powerset. Contoh hasil konversi dapat dilihat pada Tabel 3.3.

Tabel 3.3 Contoh Pelabelan Label Powerset

Label	Label Powerset
makanan positif	1
makanan negatif	2
pelayanan positif	3
pelayanan negatif	4
tempat positif	5
tempat negatif	6
harga positif	7
harga negatif	8
makanan positif,pelayanan positif	9
makanan positif,pelayanan negatif	10
makanan positif,tempat positif	11
makanan positif,tempat negatif	12
makanan positif,harga positif	13
makanan positif,harga negatif	14
makanan negatif,pelayanan negatif	15

Distribusi dari 65 kombinasi label powerset pada dataset dapat dilihat pada Gambar 3.2.

**Gambar 3.2** Distribusi Data

Berdasarkan Gambar 3.2, distribusi data antar kombinasi label powerset tidak merata, di mana sebagian besar kombinasi hanya memiliki jumlah data yang sangat sedikit. Apabila seluruh 65 kombinasi tetap digunakan, kondisi data imbalance tersebut menyebabkan model kesulitan mempelajari pola pada kombinasi dengan jumlah data sedikit, sehingga hasil evaluasi model menjadi buruk. Oleh karena itu,

penelitian ini hanya menggunakan 10 kombinasi label dengan jumlah data terbanyak. Contoh label yang digunakan dapat dilihat pada Tabel 3.4.

Tabel 3.4 Data *Label Powerset*

Label Powerset	Label	Jumlah Data
1	makanan positif	281
11	makanan positif,tempat positif	156
5	tempat positif	153
4	pelayanan negatif	96
10	makanan positif,pelayanan negatif	51
22	makanan positif,pelayanan positif,tempat positif	44
2	makanan negatif	31
12	makanan positif,tempat negatif	30
9	makanan positif,pelayanan positif	29
6	tempat negatif	29

3.5 Preprocessing

Preprocessing adalah tahap penting dalam pemrosesan data teks yang bertujuan untuk menyiapkan data agar dapat digunakan dalam model machine learning. Pada tahap ini, data teks yang ada diubah dan disesuaikan dengan format yang diperlukan untuk analisis lebih lanjut. Beberapa langkah yang dilakukan sebagai berikut.

3.5.1 Case Folding

Case folding adalah proses awal yang dilakukan untuk mengubah seluruh teks menjadi huruf kecil (lowercase). Tujuannya adalah untuk menghilangkan perbedaan yang disebabkan oleh kapitalisasi huruf. Dalam tahap ini semua huruf dalam teks akan diubah menjadi huruf kecil untuk konsistensi dan mempermudah dalam proses analisis. Contoh hasil dari tahap case folding dapat dilihat pada Gambar 3.3.

ulasan	Case Folding
Sensasi makan bebeknya luar biasa. Tekstur lembut & Sambal mangga mudanya enak. Tempat makannya selalu ramai, kalau mau bagus lagi harus diperhatikan kebersihan tempat makannya.	sensasi makan bebeknya luar biasa. tekstur lembut & sambal mangga mudanya enak. tempat makannya selalu ramai, kalau mau bagus lagi harus diperhatikan kebersihan tempat makannya.

Gambar 3.3 Contoh Hasil *Case Folding*

3.5.2 Remove Punctuation

Pada proses ini semua tanda baca yang tidak penting seperti titik, koma, tanda seru, tanda tanya, dan sebagainya dihapus. Tanda baca umumnya tidak memiliki peran penting dalam analisis sentimen dan dapat mengganggu proses tokenisasi atau pemisahan kata. Contoh hasil dari tahap *Remove Punctuation* dapat dilihat pada Gambar 3.4.

Case Folding	Remove Punctuation
sensasi makan bebeknya luar biasa. tekstur lembut & sambal mangga mudanya enak. tempat makannya selalu ramai, kalau mau bagus lagi harus diperhatikan kebersihan tempat makannya.	sensasi makan bebeknya luar biasa tekstur lembut sambal mangga mudanya enak tempat makannya selalu ramai kalau mau bagus lagi harus diperhatikan kebersihan tempat makannya

Gambar 3.4 Contoh Hasil *Remove Punctuation*

3.5.3 Tokenized

Setelah melakukan *Remove Punctuation* proses selanjutnya adalah *Tokenized*. Tokenization merupakan tahapan membagi teks menjadi bagian-bagian yang lebih kecil yang disebut token. Token bisa berupa kata, frasa, atau unit-unit lain yang dapat dianalisis. Contoh hasil dari tahap *Tokenized* dapat dilihat pada Gambar 3.5.

Remove Punctuation	Tokenized
sensasi makan bebeknya luar biasa tekstur lembut sambal mangga mudanya enak tempat makannya selalu ramai kalau mau bagus lagi harus diperhatikan kebersihan tempat makannya	[sensasi, makan, bebeknya, luar, biasa, tekstur, lembut, sambal, mangga, mudanya, enak, tempat, makannya, selalu, ramai, kalau, mau, bagus, lagi, harus, diperhatikan, kebersihan, tempat, makannya]

Gambar 3.5 Contoh Hasil *Tokenized*

3.5.4 Stopword Removal

Stopword removal merupakan tahapan dalam pengolahan bahasa alami yang bertujuan untuk meniadakan kata-kata yang dianggap tidak memiliki kontribusi signifikan terhadap analisis teks. Kata-kata ini sering muncul dalam teks secara berulang namun tidak memberikan informasi penting atau makna tambahan. Proses stopwords removal berfungsi untuk mengurangi noise dalam data dan meningkatkan efisiensi analisis dengan memfokuskan perhatian pada kata-kata yang lebih relevan dan bermakna dalam konteks analisis teks. Penelitian ini menggunakan library stopwords yang telah disediakan oleh bahasa pemrograman, yaitu NLTK. Contoh hasil dari tahap *Stopword Removal* dapat dilihat pada Gambar 3.6.

Tokenized	stopword
[sensasi, makan, bebeknya, luar, biasa, tekstur, lembut, sambal, mangga, mudanya, enak, tempat, makannya, selalu, ramai, kalau, mau, bagus, lagi, harus, diperhatikan, kebersihan, tempat, makannya]	[sensasi, makan, bebeknya, tekstur, lembut, sambal, mangga, mudanya, enak, makannya, ramai, bagus, diperhatikan, kebersihan, makannya]

Gambar 3.6 Contoh Hasil *Stopward Removal*

3.5.5 Normalization

Normalization bertujuan untuk memperbaiki kesalahan penulisan dengan mengubah kata-kata yang tidak sesuai dengan aturan ejaan menjadi bentuk yang baku, sesuai dengan standar yang ada dalam Kamus Besar Bahasa Indonesia (KBBI). Proses ini melibatkan pencocokan kata-kata tidak baku dengan kamus yang berisi daftar kata yang telah dikoreksi, lalu menggantinya dengan kata yang benar. Tujuan dari normalisasi adalah untuk memastikan bahwa data yang diproses memiliki konsistensi dalam penggunaan bahasa, sehingga analisis atau pemrosesan lebih lanjut menjadi lebih akurat dan efisien. Contoh hasil dari tahap *Normalization* dapat dilihat pada Gambar 3.7.

stopword	Normalization
[sensasi, makan, bebeknya, tekstur, lembut, sambal, mangga, mudanya, enak, makannya, ramai, bagus, diperhatikan, kebersihan, makannya]	[sensasi, makan, bebeknya, tekstur, lembut, sambal, mangga, mudanya, enak, makannya, ramai, bagus, diperhatikan, kebersihan, makannya]

Gambar 3.7 Contoh Hasil *Normalization*

3.5.6 Stemming


Stemming ialah tahapan dalam pengolahan bahasa alami yang bertujuan untuk mengubah kata-kata menjadi bentuk dasarnya dengan menghapus imbuhan seperti awalan, akhiran, atau sisipan. Tujuan stemming adalah untuk menyederhanakan variasi kata yang ada, sehingga analisis teks dapat lebih fokus pada makna inti yang terkandung dalam kata tersebut. Dalam penelitian ini, menggunakan Sastrawi, yang merupakan library Python khusus untuk stemming bahasa Indonesia. Sastrawi menggunakan algoritma tertentu untuk menghasilkan kata dasar yang sesuai dengan aturan morfologi bahasa Indonesia. Contoh hasil dari tahap *Stemming* dapat dilihat pada Gambar 3.8.

Normalization	Stemming
[sensasi, makan, bebeknya, tekstur, lembut, sambal, mangga, mudanya, enak, makannya, ramai, bagus, diperhatikan, kebersihan, makannya]	[sensasi, makan, bebek, tekstur, lembut, sambal, mangga, muda, enak, makan, ramai, bagus, perhati, bersih, makan]

Gambar 3.8 Contoh Hasil *Stemming*

3.6 TF-IDF

TF-IDF merupakan tahapan untuk ekstraksi fitur. TF-IDF adalah metode statistik yang sering dipakai untuk mengukur seberapa penting sebuah kata dalam sebuah kalimat. Proses ini terdiri dari dua langkah, yaitu TF (*Term Frequency*) dan IDF (*Inverse Document Frequency*). Alur dari TF-IDF dapat dilihat pada Gambar 3.9.



Gambar 3.9 Proses TF-IDF

Nilai TF digunakan untuk menentukan frekuensi suatu kata muncul dalam sebuah kalimat. Semakin sering kata tersebut muncul, semakin besar nilai TF-nya sehingga kata tersebut dianggap lebih penting. TF dihitung menggunakan persamaan 2.1 dan berikut adalah contoh perhitungan TF:

$$tf(t, d) = \frac{1}{3} = 0,333333$$

Sementara itu, IDF digunakan untuk menentukan sejauh mana suatu kata unik dalam kalimat. Semakin jarang kata muncul dalam seluruh dokumen, semakin tinggi nilai IDF-nya dan kata tersebut dianggap penting dalam konteks keseluruhan dokumen (*Analisis Sentimen Berbasis Aspek Pada Ulasan Pengguna Aplikasi Dompot Digital Menggunakan Metode Multinomial Naïve Bayes Skripsi Oleh:*

Hikmatul Maulidia Putri Nim. 200605110078 Program Studi Teknik Informatika
Fakultas Sains Dan Teknologi Universitas Islam Negeri Maulana Malik Ibrahim
Malang 2024, n.d.). Perhitungan IDF menggunakan persamaan 2.2:

$$\text{Idf}(t) = \text{Log}(4/1) = 0,602059991$$

Hasil perhitungan manual TF, DF, dan IDF dapat dilihat pada tabel 3.5. Dari hasil tersebut, fitur kata ‘enak’ menjadi salah satu fitur yang memiliki nilai IDF tertinggi.

Tabel 3.5 Hasil Perhitungan TF, DF, dan IDF

Kata	term					tf					df	idf
	d1	d2	d3	d4	d5	d1	d2	d3	d4	d5		
enak	1	0	0	0	0	0,333333333	0	0	0	0	1	0,698970004
bebek	1	1	1	0	0	0,333333333	0,5	0,5	0	0	3	0,22184875
nya	1	0	0	0	0	0,333333333	0	0	0	0	1	0,698970004
mantap	0	1	0	0	0	0	0,5	0	0	0	1	0,698970004
benar	0	1	0	0	0	0	0,5	0	0	0	1	0,698970004
nasi	0	0	1	0	0	0	0	0,5	0	0	1	0,698970004
dingin	0	0	1	0	0	0	0	0,5	0	0	1	0,698970004
antri	0	0	0	1	0	0	0	0	0,5	0	1	0,698970004
cepat	0	0	0	1	0	0	0	0	0,5	0	1	0,698970004
layan	0	0	0	0	1	0	0	0	0	0,5	1	0,698970004
nggak	0	0	0	0	1	0	0	0	0	0,5	1	0,698970004

TF-IDF dihitung menggunakan persmaan 2.3 berikut adalah contoh perhitungannya:

$$W_{t,d} = 0,333333 \times 0,602059991 = 0,200687$$

Hasil perhitungan dari TF_IDF dapat dilihat pada tabel 3.6.

Tabel 3.6 Hasil Perhitungan TF-IDF

Kata	tfidf				
	d1	d2	d3	d4	d5
enak	0,23299	0	0	0	0
bebek	0,07395	0,221849	0,221849	0	0
nya	0,23299	0	0	0	0
mantap	0	0,69897	0	0	0
benar	0	0,69897	0	0	0
nasi	0	0	0,69897	0	0
dingin	0	0	0,69897	0	0
antri	0	0	0	0,69897	0

cepat	0	0	0	0,69897	0
layan	0	0	0	0	0,69897
nggak	0	0	0	0	0,69897

3.7 Split Data


Split data atau pembagian data dilakukan untuk mengklasifikasikan data menjadi data training dan data testing. Dalam proses klasifikasi model, pembagian yang diterapkan adalah 80% untuk data training dan 20% untuk data testing dari keseluruhan dataset. Pemilihan rasio 80:20 didasarkan pada penelitian yang menunjukkan bahwa pembagian ini memberikan performa model yang lebih optimal dibandingkan rasio 70:30 maupun 60:40 (Alfianti & Supriyanto, 2024). Penelitian lain juga mengkonfirmasi efektivitas pembagian 80:20 dalam menghasilkan akurasi model yang tinggi untuk tugas sentiment analysis (Hendrawan et al., 2022a).

3.8 Extreme Gradient Boost (XGBOOST)

Dalam contoh perhitungan manual ini, metode XGBoost digunakan untuk mengklasifikasikan empat elemen utama yaitu makanan, pelayanan, harga, dan tempat dalam alur penelitian yang ditunjukkan pada Gambar 2.5.

3.8.1 Data Train

Data Train Perhitungan dilakukan secara bertahap hingga model optimal terbentuk sesuai dengan parameter yang telah ditentukan. Pada gambar 3.10 dapat dilihat alur dari perhitungan Training dari setiap *tree* atau pohon yang dibangun dalam xgboost.



Gambar 3.10 Alur Perhitungan Training Xgboost

1. Pada tahap awal nilai prediksi diinisialisasi menggunakan nilai logit yang sama yaitu nol. Hal ini dikarenakan pada tahap ini model belum melakukan proses pembelajaran apapun. Model diinisiasi menggunakan persamaan (2.1).

Tabel 3.7 Menentukan Probabilitas Awal

label	prediksi awal			
makanan positif	0	0	0	0
makanan positif	0	0	0	0
makanan negatif	0	0	0	0
pelayanan positif	0	0	0	0
pelayanan negatif	0	0	0	0

2. Setelah menentukan inisiasi awal, langkah berikutnya adalah menghitung probabilitas dengan softmax. Karena nilai inisiasi sebesar nol maka nilai eksponensial dari setiap kelas adalah

$$\exp(0) = 1$$

Perhitungan nilai softmax dihitung menggunakan persamaan (2.2).

$$\frac{1}{\sum_{j=1}^4 1} = \frac{1}{4} = 0.25$$

Tabel 3.8 Hasil Perhitungan Prediksi Awal

label	softmax			
makanan positif	0,25	0,25	0,25	0,25
makanan positif	0,25	0,25	0,25	0,25
makanan negatif	0,25	0,25	0,25	0,25
pelayanan positif	0,25	0,25	0,25	0,25
pelayanan negatif	0,25	0,25	0,25	0,25

3. Mengubah setiap label menjadi nilai biner sesuai jumlah kelas. Nilai 1 menunjukkan keberadaan suatu kelas pada data, sedangkan nilai 0 menunjukkan tidak adanya kelas tersebut. Tabel 3.14 merupakan hasil keseluruhan perhitungan one-hot encoding.

Tabel 3.9 Hasil Label One-Hot Encoding

label	label powerset	makanan positif	makanan negatif	pelayanan positif	tempat positif
makanan positif	1	1	0	0	0
makanan positif	1	1	0	0	0
makanan negatif	2	0	1	0	0
pelayanan positif	3	0	0	1	0
pelayanan negatif	4	0	0	0	1

4. Menghitung Gradient menggunakan persamaan (2.3) dengan menggunakan probabilitas awal dikurangi dengan label encoding sebagai label aktual nya. Perhitungan berikut merupakan contoh perhitungan untuk mencari gradient g_1 pada aspek makanan positif.

$$0.25 - 1 = -0.75$$

Tabel 3.10 Hasil Keseluruhan Perhitungan Gradient

label	g1	g2	g3	g4
makanan positif	-0,75	0,25	0,25	0,25
makanan positif	-0,75	0,25	0,25	0,25
makanan negatif	0,25	-0,75	0,25	0,25
pelayanan positif	0,25	0,25	-0,75	0,25
pelayanan negatif	0,25	0,25	0,25	-0,75

5. Menghitung Hessian menggunakan persamaan (2.4). Perhitungan berikut merupakan contoh perhitungan untuk mencari hessian h1 pada aspek makanan positif.

$$0.25(1 - 0.25) = 0.1875$$

Tabel 3.11 Hasil Perhitungan Hessian

label	h1	h2	h3	h4
makanan positif	0,1875	0,1875	0,1875	0,1875
makanan positif	0,1875	0,1875	0,1875	0,1875
makanan negatif	0,1875	0,1875	0,1875	0,1875
pelayanan positif	0,1875	0,1875	0,1875	0,1875
pelayanan negatif	0,1875	0,1875	0,1875	0,1875

6. Menghitung gain dengan persamaan (2.5) dimana dalam perhitungannya menggunakan fitur dari tf idf untuk split data nya. Contoh fitur saji dalam tf-idf dapat dilihat pada 3.12.

Tabel 3.12 Fitur Enak dalam TF-IDF

Kata	Tfidf				
	d1	d2	d3	d4	d5
enak	0,23299	0	0	0	0

Maka dalam implementasinya d1 akan masuk ke leaf kanan dan d2,d3,d4,d5 akan masuk ke leaf kiri lalu, setelah itu melakukan penjumlahan gradient dan hessian di masing masing leaf. Perhitungan berikut merupakan contoh perhitungan kelas ke-1 dari 4 kelas yang ada pada fitur enak.

$$G_{kanan} = -0,75$$

$$H_{kanan} = 0,1875$$

$$G_{kiri} = -0,75 + 0,25 + 0,25 + 0,25 \\ = 0$$

$$H_{kiri} = 0,1875 + 0,1875 + 0,1875 + 0,1875 \\ = 0,75$$

$$\lambda = 1$$

$$\gamma = 0$$

Lalu setelah mendapatkan nilai gradient dan hessian nya maka dilanjutkan dengan perhitungan gain dengan persamaan (2.7) nya yaitu:

$$\text{Gain} = -1/2 * [(0^2 / (0.75 + 1)) + (-0.75^2 / (0.1875 + 1)) - ((0 + -0.75)^2 / (0.75 + 0.1875 + 1))] - 0 \\ = 0,1878$$

Perhitungan gain di atas merupakan contoh untuk kelas ke-1. Proses yang sama dilakukan pada kelas ke-2, kelas ke-3, dan kelas ke-4. Selanjutnya, nilai gain dari masing-masing kelas dijumlahkan untuk memperoleh total gain pada setiap fitur

Tabel 3.13 Hasil Perhitungan Total Gain pada Tree Pertama

Fitur	Gain
enak	0,122241
bebek	1,050088
nya	0,122241
mantap	0,122241
benar	0,122241
nasi	0,69367
dingin	0,69367
antri	0,75288
cepat	0,75288
layan	0,69367
enggak	0,69367

Setelah menghitung *gain* dari semua fitur, langkah selanjutnya adalah memilih gain dengan nilai tertinggi yaitu *bebek*.

7. Menghitung weight node *bebek* dengan persamaan (2.8) perhitungan bobot ini didapatkan dari nilai gradient dan hessian masing-masing kelas.

Wkanan

$$\begin{aligned}\text{Kelas 1} &= -(-1,25/0,5625+1) \\ &= 0,8\end{aligned}$$

$$\begin{aligned}\text{Kelas 2} &= -(-0,25/0,5625+1) \\ &= 0,16\end{aligned}$$

$$\begin{aligned}\text{Kelas 3} &= -(0,75/0,5625+1) \\ &= -0,48\end{aligned}$$

$$\begin{aligned}\text{Kelas 4} &= -(0,75/0,5625+1) \\ &= -0,48\end{aligned}$$

Wkiri

$$\begin{aligned}\text{Kelas 1} &= -(0,5/0,375+1) \\ &= -0,36364\end{aligned}$$

$$\begin{aligned}\text{Kelas 2} &= -(0,5/0,375+1) \\ &= -0,36364\end{aligned}$$

$$\begin{aligned}\text{Kelas 3} &= -(-0,5/0,375+1) \\ &= 0,36364\end{aligned}$$

$$\begin{aligned}\text{Kelas 4} &= -(-0,5/0,932+1) \\ &= 0,36364\end{aligned}$$

8. Melakukan update prediksi dengan persamaan (2.9) Proses ini dilakukan dengan menambahkan hasil prediksi sebelumnya dengan kontribusi dari tree yang baru.

Leaf kanan

$$\begin{aligned}\text{Kelas 1} &= 0 + (0,1 * 0,8) \\ &= 0,08\end{aligned}$$

$$\begin{aligned}\text{Kelas 2} &= 0 + (0,1 * 0,16) \\ &= 0,016\end{aligned}$$

$$\begin{aligned}\text{Kelas 3} &= 0 + (0,1 * -0,48) \\ &= -0,048\end{aligned}$$

$$\begin{aligned}\text{Kelas 4} &= 0 + (0,1 * -0,48) \\ &= -0,048\end{aligned}$$

Leaf Kiri

$$\begin{aligned}\text{Kelas 1} &= 0 + (0,1 * -0,36364) \\ &= -0,03636\end{aligned}$$

$$\begin{aligned}\text{Kelas 2} &= 0 + (0,1 * -0,36364) \\ &= -0,03636\end{aligned}$$

$$\begin{aligned}\text{Kelas 3} &= 0 + (0,1 * 0,36364) \\ &= 0,03636\end{aligned}$$


$$\begin{aligned}\text{Kelas 4} &= 0 + (0,1 * 0,36364) \\ &= 0,03636\end{aligned}$$

Setelah mendapatkan nilai dari update prediksi, maka tree pertama telah terbentuk dengan nilai prediksi pada masing-masing data untuk setiap kelas. Nilai tersebut akan digunakan sebagai prediksi awal pada iterasi selanjutnya untuk menghitung gradient dan hessian yang baru.

9. Proses di atas dilakukan secara berulang dalam beberapa iterasi atau pembentukan tree. Pada setiap iterasi, model akan menghitung kembali nilai gradient dan hessian berdasarkan hasil prediksi sebelumnya untuk memperbaiki kesalahan prediksi. Setiap tree yang terbentuk akan memberikan kontribusi tambahan terhadap prediksi, sehingga nilai prediksi diperbarui secara bertahap hingga model mencapai performa yang optimal.

3.8.2 Data Test

Pada tahap pengujian, digunakan data uji berupa teks “bebek dingin” sebagai contoh perhitungan manual. Data tersebut memiliki label aktual kelas 2 (makanan negatif). Pada proses training, model hanya mempelajari kata “bebek”, sedangkan kata “dingin” tidak terdapat pada data training sehingga tidak memiliki nilai dan tidak memengaruhi proses klasifikasi. Pada gambar 3.3 dapat dilihat alur dari perhitungan Testing:



Gambar 3.11 Alur perhitungan data testing

1. Berdasarkan proses tersebut, diperoleh nilai leaf node dari masing-masing tree sebagai berikut:

Tree 1:

Kelas 1 = 0,8
 Kelas 2 = 0,16
 Kelas 3 = -0,48
 Kelas 4 = -0,48

Tree 2

Kelas 1 = 0,7618
 Kelas 2 = 0,1465
 Kelas 3 = -0,4646
 Kelas 4 = -0,4646

2. Selanjutnya nilai weight node dari setiap tree dikalikan dengan learning rate, lalu seluruh kontribusi dari seluruh tree dijumlahkan untuk memperoleh nilai logit:

$$\text{Kelas 1} = 0,08 + 0,07618 = 0,15618$$

$$\text{Kelas 2} = 0,016 + 0,01465 = 0,03065$$

$$\text{Kelas 3} = -0,048 + (-0,04646) = -0,09446$$

$$\text{Kelas 4} = -0,048 + (-0,04646) = -0,09446$$

3. Nilai logit yang diperoleh kemudian di koversi menjadi probabilitas menggunakan fungsi softmax dengan persamaan (2.2).

$$\text{Kelas 1} = 0,2929$$

$$\text{Kelas 2} = 0,2551$$

$$\text{Kelas 3} = 0,2260$$

$$\text{Kelas 4} = 0,2260$$

4. Berdasarkan hasil softmax, kelas dengan probabilitas tertinggi dipilih menggunakan fungsi argmax. Nilai tertinggi terdapat pada kelas 1 sebesar 0,2929, sehingga data uji diklasifikasikan sebagai kelas 1 (makanan positif). Nilai aktual adalah makanan negatif sedangkan prediksi nya adalah makanan positif sehingga model melakukan kesalahan dalam porses klasifikasi.
5. Confusion Matrix digunakan untuk mengevaluasi kinerja model dengan membandingkan antara nilai aktual dan hasil prediksi. Berdasarkan hasil pengujian, terdapat satu data uji dengan label aktual kelas 2 yang diprediksi sebagai kelas 1, sehingga tidak terdapat prediksi yang benar.

1. Mengitung Hamming loss dengan persamaan (2.6)

$$\text{Hamming loss} = \frac{1}{1} = 1$$

2. Menghitung precision dengan persamaan (2.7) dan (2.8)

$$\text{Precision}_1 = \frac{0}{0 + 1} = 0$$

$$\text{Precision}_{macro} = \frac{0 + 0 + 0 + 0}{4} = 0$$

3. Menghitung Recall dengan persmaan (2.9) dan (2.10)

$$\text{Recall}_2 = \frac{0}{0 + 1} = 0$$

$$\text{Recall}_{macro} = \frac{0 + 0 + 0 + 0}{4} = 0$$

4. Menghitung F1-Score dengan persmaan (2.11) dan (2.12)

$$F1 = 2 \cdot \frac{0 \cdot 0}{0 + 0} = 0$$

$$F1_{macro} = \frac{0 + 0 + 0 + 0}{4} = 0$$

6. Skenario uji coba

Berikut adalah tabel dalam skenario uji coba yang dilakukan pada tabel

Tabel 3.14 Skenario Uji Coba

Skenario	Metode	Parameter	Nilai
1	XGBoost	n_estimators	100,200,300
		learning_rate	0.1,0.2,0.3
		Max_depth	3,4,5
		lambda	0,1,2
		gamma	0,0.1,0.2
		stemming	Ya/Tidak
		n_label	65,10
2	XGBoost	n_label	3,5,7

3.9 Tools dan Library

Dalam tahap ini akan dijelaskan tools dan library apa yang akan digunakan dalam penelitian ini di antaranya:

3.9.1 Python

Python adalah bahasa pemrograman utama yang digunakan dalam penelitian ini karena kemudahan penggunaannya, dukungan komunitas yang luas, dan berbagai library yang dapat mempercepat proses analisis data dan implementasi model. Berikut adalah beberapa library Python yang digunakan dalam penelitian ini:

1. Pandas

Library ini digunakan untuk manipulasi dan analisis data. Dengan Pandas, data dapat diproses dalam bentuk DataFrame yang memudahkan pengolahan data dalam jumlah besar.

2. Numpy

NumPy adalah library untuk perhitungan numerik di Python yang menyediakan objek array multidimensi dan berbagai fungsi matematis yang efisien.

3. NLTK (*Natural Language ToolKit*)

NLTK adalah library yang digunakan untuk pengolahan bahasa alami (NLP) yang menyediakan berbagai tools untuk tokenisasi, stemming, stopword removal, dan analisis teks lainnya.

4. Sastrawi

Sastrawi adalah library Python untuk stemming Bahasa Indonesia. Dalam penelitian ini, Sastrawi digunakan untuk menghilangkan imbuhan dalam kata agar dapat mengurangi variasi kata yang tidak penting untuk analisis sentimen

5. Scikit-learn

Scikit-learn adalah library yang menyediakan berbagai algoritma machine learning, termasuk untuk klasifikasi, regresi, dan clustering. Dalam penelitian ini, Scikit-learn digunakan untuk implementasi model machine learning, seperti menggunakan teknik TF-IDF dan model klasifikasi.

6. XGBoost

XGBoost adalah library open-source yang digunakan untuk algoritma gradient boost yang efisien. Library ini mendukung pengoptimalan model melalui teknik gradient boosting yang meningkatkan performa model secara signifikan dalam proses klasifikasi.

3.9.2 Google Colab

Google Colab adalah platform berbasis cloud yang memungkinkan eksekusi kode Python dengan dukungan GPU secara gratis. Platform ini digunakan sebagai alternatif ketika menjalankan model machine learning yang membutuhkan sumber daya komputasi besar.

3.9.3 Streamlit


Streamlit adalah sebuah framework open-source yang digunakan untuk membangun aplikasi web interaktif dengan cepat dan mudah, terutama untuk keperluan data science dan machine learning. Dengan menggunakan Python, Streamlit memungkinkan pengembang untuk membuat aplikasi visualisasi data.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Pengumpulan Data

Pengumpulan data ulasan diambil dari aplikasi Google Maps. Data ulasan yang diambil berasal dari Bebek Sinjay KM.21 Gedung Baru. Data diambil menggunakan extension chrome, yaitu instant data scraper. Proses scraping dapat dilihat pada Gambar 4.1.



Gambar 4.1 Pengumpulan Data

Pengumpulan data ulasan dilakukan dengan metode scraping dari rumah makan Bebek Sinjay KM. 21 Gedung Baru. Proses dimulai dengan pencarian "Bebek Sinjay KM. 21 Gedung Baru" di Google Maps. Data diekstrak dari ulasan rumah makan tersebut melalui tautan yang telah diakses [9]. Prosedur pengambilan data meliputi membuka bagian ulasan, mengurutkannya berdasarkan yang terbaru, kemudian menggulir hingga mencapai ulasan jumlah yang diperlukan. Selanjutnya, extension Instant Data Scraper pada browser digunakan untuk mengekstrak dan menyimpan data dalam format .xlsx. Ulasan dari rumah makan Bebek Sinjay KM. 21 Gedung Baru menghasilkan sebanyak 2510 data ulasan yang dikumpulkan dari tanggal 16 April 2023 hingga 16 Januari 2025. Contoh hasil scraping dapat dilihat pada Tabel 4.1.

Tabel 4.1 Hasil Pengumpulan Dataset

Nama	Waktu	Ulasan
Nur Paws	7 jam lalu	Mantap dengan suasananya yg bikin tenang
Dafinia	12 jam lalu	Makanannya enak, cabang ini termasuk yang cukup luas
prima andika	1 hari lalu	Rekomendasi wisata kuliner di Bangkalan Sudah lama bebek ini jadi tujuan kuliner di Madura, khususnya Bangkalan ...
khusni mustaqim	1 hari lalu	Enak bebek nya
Rohmia Wati	2 hari lalu	Rame, self service dan rasa mantap
Fakih Zakaria	3 hari lalu	Ke madura kalo gamakan ini rugi, beda sama rasa yang dicabang
dul rohman	3 hari lalu	Makanan enak, bebek empuk ga alot, nasi terhitung banyak utk 1 porsi, tempat bersih luas, parkir luas, tidak nunggu lama
Rizka Harianti	seminggu lalu	Makanan ok, layanan kurang cepat
Roosi Rachma Kemala	seminggu lalu	Kalau ke Madura selalu mampir sini

4.2 Cleaning Data

Data yang telah terkumpul memerlukan proses pembersihan karena terdapat sejumlah ulasan kosong dan duplikat. Oleh karena itu, dilakukan penghapusan terhadap ulasan kosong dan ulasan yang teridentifikasi sebagai duplikat. Proses ini diimplementasikan menggunakan kode program yang dapat dilihat pada Kode Program 4.1. Setelah menyelesaikan penghapusan ulasan kosong dan duplikat, tahap cleaning data dilanjutkan dengan menghapus ulasan yang tidak menggunakan Bahasa Indonesia dan ulasan yang tidak relevan secara manual. Implementasi keseluruhan dari tahap cleaning bisa dilihat pada Kode Program 4.1.

```

1 import pandas as pd
2 df=pd.read_excel('datamentah.xlsx')
3 data_drop_nan = df.dropna()
4 data_drop_duplikat=
5 data_drop_nan.drop_duplicates(subset=['ulasan'])
data_cleaning = data_drop_duplikat.reset_index(drop=True)

```

Kode Program 4.1 Implementasi Penghapusan Ulasan Kosong dan Data Duplikat

Berikut adalah penjelasan tentang kode program dari tahapan cleaning data

1. Baris 1 mengimpor library pandas dengan alias pd. Library pandas berfungsi untuk manipulasi dan analisis data, menyediakan struktur data dan fungsi operasional tingkat tinggi untuk pengelolaan dataset dalam format DataFrame.
2. Baris 2 membaca file 'data mentah.xlsx' dan menyimpannya ke dalam DataFrame dengan nama 'data_mentah'.
3. Baris 3 melakukan penghapusan baris yang mengandung nilai kosong (NaN) dari DataFrame dan menyimpan hasilnya dalam DataFrame baru bernama 'data_drop_nan'.
4. Baris 4 menghilangkan baris-baris yang memiliki nilai identik pada kolom 'Ulasan' dari DataFrame 'data_drop_nan', kemudian menyimpannya dalam DataFrame baru 'data_drop_duplikat'. Proses ini efektif mengatasi permasalahan duplikasi dalam data ulasan.
5. Baris 5 melakukan pengaturan ulang indeks DataFrame setelah proses penghapusan duplikat selesai, dan menyimpan hasilnya dalam DataFrame baru dengan nama 'data_cleaning'.

4.3 Pelabelan Data

Dataset ulasan yang telah dilakukan proses cleaning dari Bebek Sinjay KM. 21 Gedung Baru berjumlah 1157. Mekanisme pelabelan yang digunakan dalam penelitian ini menggunakan pelabelan aspek dan label powerset. Setelah data dilabeli maka hasil dari pelabelan data dilakukan validasi oleh Bapak Dr. Bohri Rahman, M.Pd.

4.4 Preprocessing

Dalam tahap *preprocessing* data yang sudah diperoleh akan diubah menjadi data yang lebih terstruktur agar memudahkan proses selanjutnya. Tahapan *preprocessing* yang digunakan yaitu *case folding*, *remove punctuation*, *tokenization*, *stopword removal*, *normalization* dan *stemming*. Tahapan-tahapan dari *preprocessing* antara lain:

4.4.1 Case Folding

Case folding berfungsi untuk mengubah teks pada ulasan menjadi huruf kecil (*lower case*). Berikut adalah implementasi dari *case folding* pada kode program 4.2.

```

1 def case_folding(text):
2     return text.lower()

```

Kode Program 4.2 Implementasi *Case Folding*

Berikut adalah penjelasan kode program dari tahapan *case folding*:

1. Baris 1 menyatakan fungsi dengan nama *case_folding*. Fungsi ini memiliki satu parameter yaitu *text*.
2. Baris 2 berfungsi untuk mengembalikan hasil dari operasi *text.lower()*. Metode *lower()* merupakan fungsi bawaan pada objek *string* di *Python* yang mengkonversi seluruh karakter dalam *string* menjadi huruf kecil.

Hasil dari proses *case folding* dapat dilihat pada Gambar 4.2.

ulasan	Case Folding
Sensasi makan bebeknya luar biasa. Tekstur lembut & Sambal mangga mudanya enak. Tempat makannya selalu ramai, kalau mau bagus lagi harus diperhatikan kebersihan tempat makannya.	sensasi makan bebeknya luar biasa. tekstur lembut & sambal mangga mudanya enak. tempat makannya selalu ramai, kalau mau bagus lagi harus diperhatikan kebersihan tempat makannya.

Gambar 4.2 Hasil dari Proses *Case Folding*

4.4.2 *Remove Punctuation*

Dataset ulasan yang sudah didapatkan memerlukan pembersihan karena mengandung berbagai karakter yang tidak diperlukan untuk tahap berikutnya. Karakter-karakter tersebut meliputi tanda "@", URL, tanda baca, karakter non-alfabet (selain a-z), newline, dan kata tunggal yang hanya terdiri dari satu huruf. Implementasi tahap *remove punctuation* ini dapat dilihat pada Kode Program 4.3.

```

1 import re
2 import string
3 def remove_punctuation(text):
4     data = re.sub('@[^\s]+', ' ', text)
5     data = re.sub(r'http\S*', ' ', data)
6     data = data.translate(str.maketrans(' ', ' ',
7     string.punctuation))
8     data = re.sub('[^a-zA-Z]', ' ', data)
9     data = re.sub('\n', ' ', data)
10    data = re.sub(r'\b[a-zA-z]\b', ' ', data)
11    return data

```

Kode Program 4.3 Implentasi *Remove Punctuation*

Berikut adalah penjelasan kode program dari tahapan *remove punctuation*:

1. Baris 1 mengimpor modul *re* (*Regular Expression*) yang menyediakan operasi-operasi dengan *regular expression*. *Regular expression* digunakan untuk pencarian dan manipulasi *string*.

2. Baris 2 yaitu modul *string* yang menyediakan fungsi-fungsi untuk memanipulasi *string*, seperti mengakses karakter tertentu atau menghapus *whitespace*.
3. Baris 3 merupakan kode membuat fungsi `remove_punctuation` dengan parameter input `test`.
4. Baris 4 menggunakan modul `re` (*regular expression*) untuk mengganti tanda “@” diikuti oleh satu atau lebih karakter yang bukan spasi diganti dengan spasi kosong.
5. Baris 5 mengganti semua *URL* dalam teks dengan spasi kosong.
6. Baris 6 menghapus semua tanda baca dari teks menggunakan metode `translate()` pada *string*. Tanda baca yang dihapus didefinisikan oleh `string.punctuation`.
7. Baris 7 mengganti semua karakter yang bukan huruf alfabet dengan spasi kosong.
8. Baris 8 mengganti setiap karakter *newline* “\n” dengan spasi kosong.
9. Baris 9 mengganti setiap kata tunggal yang hanya terdiri dari satu huruf dengan spasi kosong.
10. Baris 10 fungsi untuk mengembalikan teks hasil dari proses *remove punctuation*.

Hasil dari proses *remove punctuation* dapat dilihat pada gambar 4.3

Case Folding	Remove Punctuation
sensasi makan bebeknya luar biasa. tekstur lembut & sambal mangga mudanya enak. tempat makannya selalu ramai, kalau mau bagus lagi harus diperhatikan kebersihan tempat makannya.	sensasi makan bebeknya luar biasa tekstur lembut sambal mangga mudanya enak tempat makannya selalu ramai kalau mau bagus lagi harus diperhatikan kebersihan tempat makannya

Gambar 4.3 Hasil dari Proses *Remove Punctuation*

4.4.3 Tokenization

Tokenization adalah sebuah proses untuk memisahkan dokumen menjadi per kata. Pada tahap ini, setiap dokumen menghasilkan kata-kata yang dipisahkan oleh tanda koma. Berikut adalah implementasi dari tahap *tokenization* pada kode program 4.4.

```

1 import nltk
2 nltk.download('punkt')
3 nltk.download('punkt_tab')
4 def tokenize(text):
5     return nltk.word_tokenize(text)

```

Kode Program 4.4 Implementasi *Tokenization*

Berikut adalah penjelasan kode program dari tahapan *tokenization*:

1. Baris 1 yaitu modul NLTK (Natural Language Toolkit) yang digunakan untuk pemrosesan bahasa alami.
2. Baris 2 mengunduh modul punkt dari nltk yang digunakan untuk proses tokenisasi teks.
3. Baris 3 mengunduh modul punkt_tab sebagai pendukung proses tokenisasi pada nltk.
4. Baris 4-5 membuat fungsi tokenize dengan parameter input text. Fungsi ini menggunakan word_tokenize dari nltk untuk memisahkan teks menjadi token-token berupa kata berdasarkan spasi dan tanda baca. Hasil tokenisasi kemudian dikembalikan dalam bentuk daftar kata. Hasil dari proses *tokenization* dapat dilihat pada tabel 4.4.

Remove Punctuation	Tokenized
sensasi makan bebeknya luar biasa tekstur lembut sambal mangga mudanya enak tempat makannya selalu ramai kalau mau bagus lagi harus diperhatikan kebersihan tempat makannya	[sensasi, makan, bebeknya, luar, biasa, tekstur, lembut, sambal, mangga, mudanya, enak, tempat, makannya, selalu, ramai, kalau, mau, bagus, lagi, harus, diperhatikan, kebersihan, tempat, makannya]

Gambar 4.4 Hasil dari Proses *Tokenization*

4.4.4 *Stopword Removal*

Stopword removal adalah tahapan yang berfungsi untuk menghilangkan kata yang tidak penting yang termasuk dalam stoplist. Pada tahap stopwords removal memanfaatkan library stopwords yang telah tersedia dalam Natural Language Toolkit (NLTK). Berikut merupakan implementasi dari stopwords removal pada kode program 4.5.

```

1 from nltk.corpus import stopwords
2 import nltk
3 nltk.download('stopwords')
4 def remove_stopword(ulasan):
5     stopword = []
6     for word in ulasan:
7         if word not in stopwords.words('indonesian'):
8             stopword.append(word)

```

9	return stopword
---	-----------------

Kode Program 4.5 Implementasi *Stopword Removal*

Berikut adalah penjelasan kode program dari tahapan *stopword removal*.

1. Baris 1 mengimpor modul `stopwords` dari *library* `nltk` untuk mengakses daftar `stopword`.
2. Baris 2 mengimpor *library* `nltk` agar fungsi pada *library* dapat digunakan.
3. Baris 3 mengunduh dataset *stopwords* dari `nltk`.
4. Baris 4-9 membuat fungsi `remove_stopword` dengan input ulasan. Dibatasi list kosong `stopword` untuk menyimpan hasil *filtering*. Selanjutnya dilakukan perulangan pada setiap kata dalam ulasan. Jika kata tidak termasuk `stopword` bahasa Indonesia, maka kata tersebut ditambahkan ke dalam list `stopword`. Setelah proses selesai, fungsi mengembalikan hasil `stopword removal`. Hasil dari proses *Stopword Removal* dapat dilihat pada gambar 4.5.

Tokenized	stopword
[sensasi, makan, bebeknya, luar, biasa, tekstur, lembut, sambal, mangga, mudanya, enak, tempat, makannya, selalu, ramai, kalau, mau, bagus, lagi, harus, diperhatikan, kebersihan, tempat, makannya]	[sensasi, makan, bebeknya, tekstur, lembut, sambal, mangga, mudanya, enak, makannya, ramai, bagus, diperhatikan, kebersihan, makannya]

Gambar 4.5 Hasil dari Proses *Stopword Removal*

4.4.5 Normalization

Data ulasan yang diperoleh dari pengguna tidak semua dalam bentuk baku, dengan sejumlah kata yang mengalami penyingkatan atau kesalahan pengetikan. Normalisasi kata dilakukan dengan menggunakan kamus alay yang dihasilkan dari penelitian sebelumnya (Aliyah Salsabila et al., 2018). Berikut merupakan implementasi dari tahap *normalization* pada kode program 4.6.

1	kamus_normalisasi = pd.read_csv('colloquial-indonesian-lexicon.csv')
2	kamus_normalisasi = kamus_normalisasi.drop(columns=['In-dictionary', 'context', 'category1', 'category2', 'category3'])
3	def normalization(token):
4	ulasan_normalisasi = []
5	for kata in token:
6	if kata in kamus_normalisasi['slang'].values:
7	formal = kamus_normalisasi.loc[kamus_normalisasi['slang'] == kata, 'formal'].values[0]
8	ulasan_normalisasi.append(formal)
9	else:
10	ulasan_normalisasi.append(kata)

11	<code>return ulasan_normalisasi</code>
----	--

Kode Program 4.6 Implementasi *Normalization*

Berikut adalah penjelasan kode program dari tahapan *normalization*.

1. Baris 1 mengimplementasikan penggunaan pustaka *pandas* untuk mengakses dan memuat data dari berkas CSV '*colloquial-indonesian-lexicon.csv*', kemudian data tersebut disimpan dalam struktur *DataFrame* dengan nama variabel *kamus_normalisasi*.
2. Baris 2 dilakukan proses eliminasi sejumlah kolom yaitu *In-dictionary*, *context*, *category1*, *category2*, dan *category3* dari *DataFrame* yang telah tersimpan dalam variabel *kamus_normalisasi*.
3. Baris 3 membuat fungsi *normalization* dengan parameter input *token*.
4. Baris 4 membuat list kosong *ulasan_normalisasi* untuk menyimpan hasil normalisasi kata.
5. Baris 5-10 melakukan perulangan pada setiap kata dalam *token*. Kata diperiksa apakah terdapat pada kolom '*slang*' di *kamus_normalisasi*. Jika ditemukan, maka kata slang diubah menjadi bentuk formal berdasarkan kolom *formal* dan ditambahkan ke dalam *ulasan_normalisasi*. Jika tidak ditemukan, maka kata asli langsung ditambahkan tanpa perubahan.
6. Baris 11 mengembalikan list *ulasan_normalisasi* yang berisi kata-kata hasil normalisasi.

Hasil dari proses *Normalization* dapat dilihat pada gambar 4.6.

stopword	Normalization
[sensasi, makan, bebeknya, tekstur, lembut, sambal, mangga, mudanya, enak, makannya, ramai, bagus, diperhatikan, kebersihan, makannya]	[sensasi, makan, bebeknya, tekstur, lembut, sambal, mangga, mudanya, enak, makannya, ramai, bagus, diperhatikan, kebersihan, makannya]

Gambar 4.6 Hasil dari Proses *Normalization*

4.4.6 *Stemming*

Stemming adalah proses transformasi kata-kata yang berimbuhan menjadi bentuk kata dasar. Dalam proses *stemming* memanfaatkan library python, yaitu *Sastrawi*.

Berikut merupakan implementasi dari stemming pada kode program 4.7.

```

1  from Sastrawi.Stemmer.StemmerFactory import
    StemmerFactory
2  Fact = StemmerFactory()
3  Stemmer = Fact.create_stemmer()
4  def stemming(ulasan):
5      hasil = []
6      for word in ulasan:
7          hasil.append(Stemmer.stem(word))
8      return hasil

```

Kode Program 4.7 Implementasi *Stemming*

Berikut adalah penjelasan kode program dari tahapan *stemming*.

1. Baris 1 melakukan impor kelas StemmerFactory dari modul Stemmer yang terdapat dalam pustaka Sastrawi untuk keperluan proses stemming teks berbahasa Indonesia.
2. Baris 2 menginisialisasi objek dari kelas StemmerFactory yang telah diimpor sebelumnya sebagai dasar pembuatan objek stemmer.
3. Baris 3 menghasilkan objek stemmer melalui pemanggilan metode create_stemmer() dari StemmerFactory untuk melaksanakan operasi stemming terhadap kata-kata.
4. Baris 4 hingga 7 mendefinisikan fungsi stemming yang menerima parameter ulasan sebagai input. Fungsi ini menginisialisasi list kosong bernama result, kemudian melakukan iterasi pada setiap kata dalam ulasan untuk diproses menggunakan metode stem() dari objek Stemmer, dan menyimpan hasilnya ke dalam *list result*.
5. Baris 8 berfungsi mengembalikan *list result* yang memuat koleksi kata-kata hasil proses stemming. Hasil dari proses *Stemming* dapat dilihat pada gambar 4.7.

Normalization	Stemming
[sensasi, makan, bebeknya, tekstur, lembut, sambal, mangga, mudanya, enak, makannya, ramai, bagus, diperhatikan, kebersihan, makannya]	[sensasi, makan, bebek, tekstur, lembut, sambal, mangga, muda, enak, makan, ramai, bagus, perhati, bersih, makan]

Gambar 4.7 Hasil dari Proses *Stemming*

Setelah melalui seluruh tahapan preprocessing, diperoleh hasil preprocessing akhir yang akan digunakan pada proses pembobotan TF-IDF. Contoh hasil preprocessing dapat dilihat pada Tabel 4.8.

ulasan	Hasil Preprocessing
Sensasi makan bebeknya luar biasa. Tekstur lembut & Sambal mangga mudanya enak. Tempat makannya selalu ramai, kalau mau bagus lagi harus diperhatikan kebersihan tempat makannya.	sensasi makan bebek tekstur lembut sambal mangga muda enak makan ramai bagus perhati bersih makan

Gambar 4.8 Hasil dari Pre Processing

4.5 Konversi Biner Multi-Label

Dalam tahap ini, label akan dikonversi menjadi format biner untuk memungkinkan klasifikasi multi-label. Konversi biner multi-label merupakan proses transformasi data label yang memiliki lebih dari satu kategori menjadi representasi biner, di mana setiap label dikodekan sebagai vektor biner dengan nilai 1 untuk label positif dan 0 untuk label negatif. Berikut merupakan implementasi dari tahap konversi biner pada kode program 4.8.

```

1 df['Label'] = df['Label'].apply(lambda x:
2   x.split(', '))
3   mlb = MultiLabelBinarizer()
4   y = mlb.fit_transform(df['Label'])

```

Kode Program 4.8 Implementasi Konversi Biner

Berikut adalah penjelasan kode program dari tahapan Konversi Biner.

1. Baris 1 yaitu memisahkan string label yang dipisahkan koma menjadi list menggunakan fungsi `.apply()` dengan lambda function. Kolom 'Label' yang sebelumnya berisi string seperti "label1,label2,label3" akan diubah menjadi list seperti ["label1", "label2", "label3"].
2. Baris 2 yaitu membuat objek dari kelas `MultiLabelBinarizer` yang digunakan untuk mengonversi label dalam format list menjadi representasi biner multi-label. Objek `mlb` ini akan menangani proses transformasi dari format list ke matriks biner.
3. Baris 3 yaitu melakukan proses fitting dan transformasi pada kolom 'Label' menggunakan metode `.fit_transform()`. Variabel `y` berisi matriks biner di mana setiap kolom adalah satu label dan setiap baris adalah satu sampel dengan nilai 1 untuk label positif dan 0 untuk yang negatif.

4.6 TF-IDF

TF-IDF digunakan untuk pembobotan kata dan menilai tingkat kepentingan kata dalam dokumen. Dalam prosesnya TF-IDF menggunakan modul `scikit-`

learn dari library python. Berikut merupakan implementasi dari tahap TF-IDF pada kode program 4.9.

```

1  from sklearn.feature_extraction.text import
    TfidfVectorizer
2  vectorizer = TfidfVectorizer()
3  X = vectorizer.fit_transform(df['Pre
    Processing'])
4  df_tfidf=pd.DataFrame(X.toarray(),
5  columns=vectorizer.get_feature_names_out())

```

Kode Program 4.9 Implementasi TF-IDF

Berikut penjelasan kode program dari tahapan TF-IDF.

1. Baris 1 yaitu mengimpor `TfidfVectorizer` dari *library* scikit-learn yang berguna untuk mengonversi kumpulan teks dokumen menjadi matriks TF-IDF.
2. Pada baris 2 yaitu membuat objek dari kelas `TfidfVectorizer` dan menginisiasinya dengan pengaturan default. Objek `vectorizer` ini akan digunakan untuk melakukan transformasi teks menjadi representasi TF-IDF.
3. Baris 3 yaitu melakukan proses fitting dan transformasi sekaligus pada kolom 'Pre Processing' dari `DataFrame` `df` menggunakan metode `.fit_transform()`. Variabel `X` sekarang berisi matriks TF-IDF dalam bentuk matrix yang merepresentasikan bobot TF-IDF untuk setiap kata dalam setiap dokumen.
4. Baris 4 yaitu membuat `DataFrame` dari matriks TF-IDF dengan mengonversi matrix `X` menjadi array menggunakan `.toarray()`, kemudian menggunakan `.get_feature_names_out()` untuk mendapatkan nama-nama fitur (kata-kata) sebagai nama kolom.

Sampel hasil dari proses TF-IDF dapat dilihat pada tabel 4.2

Tabel 4.2 Hasil sampel TF-IDF

Doc	acuh	ad	ada	adalah	adanya		zonk
1	0	0	0,119305	0	0		0
2	0	0	0	0	0		0
3	0	0	0	0	0		0
4	0	0	0,24334	0	0		0
5	0	0	0,107272	0	0		0

4.7 Split Data

Setelah melakukan pembobotan TF-IDF dan data sekarang akan menampilkan dalam bentuk vektor. Selanjutnya melakukan *split* data untuk membagi data menjadi dua yaitu data *training* dan data *test*. Berikut merupakan implementasi dari tahap *split* data pada Kode Program 4.10.

1	from sklearn.model_selection import
	train_test_split
2	X_train, X_test, y_train, y_test =
	train_test_split(X, y, test_size=0.2,
	random_state=42)

Kode Program 4.10 Implementasi split Data

Berikut penjelasan kode program dari tahapan *Split* data.

1. Baris 1 yaitu mengimpor library `sklearn` yaitu fungsi `train_test_split` dari `model_selection` yang digunakan untuk membagi dataset menjadi dua yaitu data *train* dan data *test*.
2. Baris 2 yaitu memanggil fungsi `train_test_split` yang membagi dataset menjadi empat bagian, yaitu `X_train`, `X_test`, `y_train`, dan `y_test`. `X` merupakan matriks fitur yang didapatkan dari hasil TF-IDF yang digunakan dalam proses training. Sedangkan `y` adalah array yang berisi label kelas sebagai target. Nilai `test_size = 0.2` menentukan proporsi dataset yang digunakan sebagai data *test*. Sementara itu, `random_state = 42` menetapkan seed untuk pembangkit angka acak, sehingga pembagian data *train* dan data *test* konsisten setiap kali kode dijalankan kembali.

4.8 Klasifikasi Multi-Label XGBOOST

Setelah melakukan *split* data dan mendapatkan nilai untuk data seperti data *train* dan data *test* selanjutnya akan dilakukan klasifikasi menggunakan Extreme Gradient Boosting (XGBoost).

```

1  model = XGBClassifier(
2      objective      = 'multi:softmax',
3      num_class      = len(le_lp.classes_),
4      eval_metric    = 'mlogloss',
5      n_estimators   = n_esti,
6      learning_rate  = lr,
7      max_depth      = md,
8      reg_lambda     = lam,
9      gamma          = g,
10     n_jobs         = -1
11 )
12 model.fit(X_train, y_train_enc)
13 y_pred_enc = model.predict(X_test)

```

Kode Program 4.11 Implementasi klasifikasi XGBOOST

Berikut penjelasan kode program dari tahapan klasifikasi XGBOOST:

1. Baris 1–9 melakukan inisialisasi model XGBoost beserta parameter yang digunakan pada penelitian.
2. Parameter `objective='multi:softmax'` digunakan untuk melakukan klasifikasi multiclass hasil transformasi Label Powerset.
3. Parameter `num_class` menentukan jumlah kelas unik Label Powerset yang digunakan dalam proses klasifikasi.
4. Parameter `eval_metric='mlogloss'` digunakan sebagai fungsi evaluasi selama proses training.
5. Parameter `n_estimators` menentukan jumlah tree yang dibangun.
6. Parameter `learning_rate` mengatur besar kontribusi setiap tree terhadap model.
7. Parameter `max_depth` menentukan kedalaman maksimum tree.
8. Parameter `reg_lambda` digunakan untuk mengurangi overfitting melalui regularisasi.
9. Parameter `gamma` menentukan nilai minimum gain yang diperlukan untuk melakukan pemisahan node.
10. Parameter `n_jobs=-1` digunakan untuk memanfaatkan seluruh core CPU yang tersedia.
11. Baris `model.fit(X_train, y_train_enc)` digunakan untuk melatih model menggunakan data training.
12. Baris `model.predict(X_test)` digunakan untuk menghasilkan prediksi pada data testing.

4.9 Lingkungan Pengujian

Pada bagian ini mendeskripsikan spesifikasi perangkat yang digunakan selama melakukan pembuatan dan pengujian sistem. Spesifikasi perangkat yang digunakan dapat terlihat pada Tabel 4.3

Tabel 4.3 Spesifikasi Perangkat

No	Kebutuhan	Jenis
1	Sistem Operasi	Windows 11 Home Single Language 64-bit
2	Processor	12th Gen Intel(R) Core(TM) i5-1235U 1.30 GHz
3	RAM	8000 MB

4.10 Implementasi Antar Muka

Berikut ini adalah halaman antar muka untuk pengujian aplikasi analisis sentimen berbasis aspek. pada ulasan Bebek Sinjay menggunakan metode Label Powerset dan XGBoost. Gambar 4.4 menunjukkan tampilan antarmuka aplikasi sebelum proses analisis dilakukan. Pengguna dapat memasukkan ulasan pada area teks yang tersedia, kemudian menekan tombol proses untuk memperoleh hasil analisis berupa aspek yang teridentifikasi beserta sentimen yang dihasilkan dari ulasan tersebut.

Aplikasi Analisis Sentimen Berbasis Aspek Ulasan Rumah Makan Bebek Sinjay

Masukkan Ulasan

Proses

Gambar 4.9 Tampilan Antar Muka Aplikasi

Gambar merupakan tampilan antar muka dari aplikasi setelah ulasan berhasil di analisis sehingga dapat menunjukkan aspek dan sentimen yang terkandung dalam ulasan

Aplikasi Analisis Sentimen Berbasis Aspek Ulasan Rumah Makan Bebek Sinjay

Masukkan Ulasan

Proses

Gambar 4.10 Tampilan Antar Muka Aplikasi Setelah Diproses

4.11 Hasil Skenario Pengujian

Untuk menjawab pertanyaan penelitian mengenai nilai terbaik dari Hamming Loss, Precision, Recall, dan F1 Score pada analisis sentimen berbasis aspek ulasan Bebek Sinjay menggunakan metode Label Powerset dan XGBoost, dilakukan serangkaian skenario pengujian. Skenario pengujian dilakukan dengan menerapkan berbagai kombinasi hyperparameter XGBoost. Pemilihan model terbaik dilakukan berdasarkan hasil evaluasi yang diperoleh dari setiap skenario pengujian, kemudian model dengan nilai F1 Score tertinggi dan Hamming Loss terendah dipilih untuk digunakan pada tahap pengujian aplikasi.

Tabel 4.4 Skenario Pengujian

Skenario	Metode	Parameter	Nilai
1	XGBoost	n_estimators	100,200,300
		learning_rate	0.1,0.2,0.3
		Max_depth	3,4,5
		lambda	0,1,2
		gamma	0,0.1,0.2
		stemming	Ya/Tidak
		n_label	65,10
2	XGBoost	n_label	3,5,7

Berdasarkan skenario pengujian yang telah dirancang pada tabel 4.4, dilakukan pengujian terhadap beberapa kombinasi hyperparameter XGBoost yang meliputi `n\_estimators`, `learning\_rate`, `max\_depth`, `reg\_lambda`, dan `gamma`. Setiap kombinasi parameter digunakan untuk membangun model dan dievaluasi menggunakan data testing yang diperoleh dari proses pembagian data sebelumnya.

Tabel 4.5 Parameter Skenario 1

n_label	Stemming	n_estimator	Learning_rate	Max_dpeth	lambda	gamma
65	Ya	300	0.3	3	3	0
65	Tidak	100	0.3	5	2	0.1
10	Ya	300	0.3	4	2	0
10	Tidak	200	0.3	5	2	0.1

Hasil evaluasi berupa nilai Hamming Loss, Precision, Recall, dan F1 Score dihitung untuk setiap skenario pengujian. Dari seluruh kombinasi parameter yang diuji, diperoleh 243 skenario pengujian. Selanjutnya, hasil dari setiap skenario dibandingkan untuk menentukan model terbaik. Berdasarkan nilai F1 Score tertinggi dan Hamming Loss terendah. Parameter terbaik yang diperoleh dari hasil grid search dapat dilihat pada Tabel 4.5. Hasil evaluasi model terbaik dari setiap kondisi dapat dilihat pada Tabel 4.6.

Tabel 4.6 Hasil Evaluasi Skenario 1

n_label	Stemming	Hamming Loss	Precision	Recall	F1-Score
65	Ya	0.524	0.116	0.085	0.098
65	Tidak	0.156	0.131	0.093	0.109
10	Ya	0.388	0.55	0.452	0.496
10	Tidak	0.4	0.472	0.408	0.438

Berdasarkan Tabel 4.6, penggunaan 10 kombinasi Label Powerset menghasilkan performa yang lebih baik yaitu dengan Hamming loss 0.388 dan F1-Score 0.496 dibandingkan 65 kombinasi Label Powerset. Hal ini disebabkan oleh distribusi data pada 65 kombinasi label yang tidak seimbang sehingga memengaruhi kemampuan model dalam mengenali pola pada beberapa kelas.

Selanjutnya dilakukan pengujian Skenario 2 dengan memvariasikan jumlah label menggunakan parameter terbaik yang diperoleh dari Skenario 1, yaitu $n_estimators=300$, $learning_rate=0.3$, $max_depth=4$, $reg_lambda=2$, dan $gamma=0$ dengan stemming. Pengujian dilakukan pada 3, 5, dan 7 label. Hasil pengujian Skenario 2 dapat dilihat pada Tabel 4.7.

Tabel 4.7 Hasil Evaluasi Skenario 2

n_label	Hamming Loss	Precision	Recall	F1-Score
3	0.237	0.747	0.697	0.721
5	0.277	0.63	0.588	0.609
7	0.429	0.658	0.442	0.529

Berdasarkan Tabel 4.7 penggunaan 3 label menghasilkan performa terbaik dengan nilai Hamming Loss terendah sebesar 0.237 dan F1 Score tertinggi sebesar 0.721. Hasil tersebut menunjukkan bahwa jumlah label yang digunakan memengaruhi performa model. Perbedaan performa yang dihasilkan dapat disebabkan oleh distribusi data pada setiap kelas yang memengaruhi kemampuan model dalam mempelajari pola data.

4.12 Analisis Hasil

Berdasarkan hasil skenario pengujian yang telah dilakukan, diperoleh perbedaan performa pada setiap kondisi pengujian. Perbedaan tersebut menunjukkan bahwa jumlah kombinasi Label Powerset dan penggunaan preprocessing berpengaruh terhadap kemampuan model dalam melakukan klasifikasi aspek dan sentimen.

Pada skenario pertama, penggunaan 10 kombinasi Label Powerset dengan stemming menghasilkan performa terbaik dibandingkan kondisi lainnya. Hal ini ditunjukkan oleh nilai F1 Score yang lebih tinggi dan Hamming Loss yang lebih rendah. Distribusi data yang lebih seimbang pada setiap kelas memungkinkan model mempelajari pola data dengan lebih baik sehingga menghasilkan performa klasifikasi yang lebih optimal. Sebaliknya, penggunaan 65 kombinasi Label Powerset menghasilkan performa yang lebih rendah. Kondisi ini disebabkan oleh ketidakseimbangan distribusi data antar kelas, dimana beberapa kombinasi label memiliki jumlah data yang jauh lebih sedikit dibandingkan kelas lainnya. Akibatnya, model mengalami kesulitan dalam mempelajari pola pada kelas minoritas sehingga memengaruhi performa klasifikasi secara keseluruhan.

Selain itu, penggunaan stemming memberikan hasil yang lebih baik dibandingkan tanpa stemming. Proses stemming membantu mengubah kata

menjadi bentuk dasarnya sehingga variasi kata yang memiliki makna sama dapat direpresentasikan secara lebih konsisten. Hal ini membantu model dalam mengenali pola data dan meningkatkan performa klasifikasi.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan penelitian yang telah dilakukan pada analisis sentimen berbasis aspek ulasan Bebek Sinjay menggunakan metode Label Powerset dan XGBoost, diperoleh beberapa kesimpulan. Pada Skenario 1, model terbaik diperoleh menggunakan 10 kombinasi Label Powerset dengan stemming dan parameter `n_estimators=300`, `learning_rate=0,3`, `max_depth=4`, `reg_lambda=2`, serta `gamma=0`. Model tersebut menghasilkan Hamming Loss sebesar 0,388, Precision sebesar 0,550, Recall sebesar 0,452, dan F1 Score sebesar 0,496. Performa yang lebih baik dibandingkan penggunaan 65 kombinasi Label Powerset menunjukkan bahwa distribusi data yang lebih seimbang membantu model dalam mempelajari pola data dengan lebih optimal. Pada Skenario 2, hasil terbaik diperoleh menggunakan 3 label dengan Hamming Loss sebesar 0,228, Precision sebesar 0,781, Recall sebesar 0,709, dan F1 Score sebesar 0,743. Namun, penelitian ini tetap berfokus pada penggunaan 10 kombinasi Label Powerset karena mampu merepresentasikan kombinasi aspek dan sentimen secara lebih komprehensif. Secara keseluruhan, hasil penelitian menunjukkan bahwa jumlah data dan ketidakseimbangan distribusi antar kombinasi label masih menjadi faktor yang memengaruhi performa model.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran untuk penelitian selanjutnya

1. Penambahan jumlah dataset yang lebih banyak dan seimbang antar kombinasi label diharapkan dapat meningkatkan performa model, mengingat ketidakseimbangan data menjadi salah satu faktor yang memengaruhi hasil evaluasi pada penelitian ini.
2. Penelitian selanjutnya dapat mencoba metode lain untuk menangani ketidakseimbangan data, seperti SMOTE atau oversampling sebelum dilakukan proses klasifikasi.

3. Penelitian selanjutnya dapat mempertimbangkan penggunaan metode deep learning seperti BERT berbasis bahasa Indonesia untuk meningkatkan kemampuan model dalam memahami konteks ulasan.

DAFTAR PUSTAKA

- Alfianti, M. L. T., & Supriyanto, R. (2024). Perbandingan Kinerja Algoritma Random Forest, AdaBoost, dan XGBoost Dalam Memprediksi Resiko Penyakit Osteoporosis. *Jurnal Ilmu Komputer Dan Agri-Informatika*, 11(2), 172–184.
- Aliefia, A. Y., & Irawan, M. I. (2025). Perbandingan Metode Extreme Gradient Boosting (XGBoost) dan Light Gradient Boosting Machine (LightGBM) untuk Mendeteksi Fraud pada Data Klaim Asuransi Kendaraan Bermotor. *Jurnal Sains Dan Seni ITS*, 13(4), A44–A51.
- Aliyah Salsabila, N., Ardhito Winatmoko, Y., Akbar Septiandri, A., & Jamal, A. (2018). Colloquial Indonesian Lexicon. *Proceedings of the 2018 International Conference on Asian Language Processing, IALP 2018*, 226–229. <https://doi.org/10.1109/IALP.2018.8629151>
- Analisis Sentimen Berbasis Aspek Pada Ulasan Pengguna Aplikasi Dompot Digital Menggunakan Metode Multinomial Naïve Bayes Skripsi Oleh: Hikmatul Maulidia Putri Nim. 200605110078 Program Studi Teknik Informatika Fakultas Sains Dan Teknologi Universitas Islam Negeri Maulana Malik Ibrahim Malang 2024. (n.d.).*
- Bebek Sinjay KM. 21 Gedung Baru. (n.d.).* Google Maps. Retrieved January 16, 2025, from https://www.google.com/maps/place/Bebek+Sinjay+KM.+21+Gedung+Baru/@-7.0306918,112.581723,11z/data=!4m2!1m2!1sbebek+sinjay!3m8!1s0x2dd805995a2829eb:0xecbd0c5e67786379!8m2!3d-7.0437951!4d112.7781624!9m1!1b1!15sCgxiZWJlayBzaW5qYXlaDiIMYmViZWsgc2luamF5kgEVaW5kb25lc2lhb19yZXN0YXVyYW504AEA!16s%2Fg%2F11jnr!1j1y1?entry=tту&g_ep=EgoyMDI1MDExNS4wIKXMDSoASAFQAw%3D%3D
- Boosting in Machine Learning. (n.d.).* Retrieved June 20, 2025, from <https://www.geeksforgeeks.org/machine-learning/boosting-in-machine-learning-boosting-and-adaboost/>
- Christanto, H., Rahmad, J., Sinurat, S. H., Hamonangan Sitompul, D. R., Sitomorang, A., Ziegel, D. J., & Indra, E. (2023). Analisis Perbandingan Decision Tree, Support Vector Machine, dan Xgboost dalam Mengklasifikasi Review Hotel Trip Advisor. *Jurnal Teknologi Informatika Dan Komputer*, 9(1), 306–319. <https://doi.org/10.37012/jtik.v9i1.1429>
- Duman, E. (2022). Implementation of XGBoost Method for Healthcare Fraud Detection. *Scientific Journal of Mehmet Akif Ersoy University*, 5(2), 69–75.
- Dwigi Sepbriant, G., & Utomo, W. (2024). Ensemble Learning pada Kategorisasi Produk E-Commerce Menggunakan Teknik Boosting. In *Jurnal Informatika Sunan Kalijaga* (Vol. 9, Number 2). MEI.
- Ensemble Learning: Bagging & Boosting. (n.d.).* Retrieved June 20, 2025, from <https://towardsdatascience.com/ensemble-learning-bagging-boosting-3098079e5422/>
- Erkamim, Moh., Tanniewa, A. M., AP, I., & Nurhayati, N. (2024). Analisis Perbandingan Metode AdaBoost, Gradient Boosting, dan XGBoost Untuk Kalsifikasi Status Gizi

- Pada Balita. *Building of Informatics, Technology and Science (BITS)*, 6(3), 1799–1807. <https://doi.org/10.47065/bits.v6i3.5717>
- Fadlilah, I. N., Wahyuni, E. D., Permatasari, R., Informasi, S., Pembangunan, U., Veteran, N. ", Timur, J., Raya, J., Madya, R., & Anyar, G. (2025). Komparasi Metode Label Powerset K-NN Dan ML-KNN Dalam Klasifikasi Multi-Label Cyberbullying Pada Komentar Instagram. In *Jurnal Mahasiswa Teknik Informatika* (Vol. 9, Number 3).
- Firdaus, M. F., Ratnawati, D. E., & Setiawan, N. Y. (2024). Analisis Sentimen Berbasis Aspek Pada Ulasan Pelanggan Restoran Menggunakan Algoritma Support Vector Machine (Studi Kasus: Depot Bamara). *Jurnal Teknologi Informasi Dan Ilmu Komputer*, 11(6), 1265–1272.
- Fitriani¹, E. E., & Yustanti², W. (2022). *Perbandingan Kinerja Metode Problem Transformation-KNN dan Algorithm Adaptation-KNN pada Klasifikasi Multi-Label Pertanyaan Kotakode*.
- Givari, M. R., Mochamad, R., & Sulaeman², Y. U. (2022). *Perbandingan Algoritma SVM, Random Forest Dan XGBoost Untuk Penentuan Persetujuan Pengajuan Kredit*. 16(1). <https://journal.uniku.ac.id/index.php/ilkom>
- Hendrawan, I. R., Utami, E., & Hartanto, A. D. (2022a). Comparison of Naïve Bayes Algorithm and XGBoost on Local Product Review Text Classification. *Edumatic: Jurnal Pendidikan Informatika*, 6(1), 143–149. <https://doi.org/10.29408/edumatic.v6i1.5613>
- Hendrawan, I. R., Utami, E., & Hartanto, A. D. (2022b). Comparison of Naïve Bayes Algorithm and XGBoost on Local Product Review Text Classification. *Edumatic: Jurnal Pendidikan Informatika*, 6(1), 143–149. <https://doi.org/10.29408/edumatic.v6i1.5613>
- Luaces, O., Díez, J., Barranquero, J., del Coz, J. J., & Bahamonde, A. (2012). Binary relevance efficacy for multilabel classification. *Progress in Artificial Intelligence*, 1(4), 303–313. <https://doi.org/10.1007/s13748-012-0030-x>
- Mathayomchan, B., & Taecharungroj, V. (2020). “How was your meal?” Examining customer experience using Google maps reviews. *International Journal of Hospitality Management*, 90. <https://doi.org/10.1016/j.ijhm.2020.102641>
- Morama, H. C., Ratnawati, D. E., & Arwani, I. (2022). Analisis Sentimen berbasis Aspek terhadap Ulasan Hotel Tentrem Yogyakarta menggunakan Algoritma Random Forest Classifier. *Jurnal Pengembangan Teknologi Informasi Dan Ilmu Komputer*, 6(4), 1702–1708.
- Mufidah, U. (2022). Perancangan Aplikasi Perbandingan Harga Produk (Historical Data) Menggunakan Teknik Scraping Web. *Jurnal Pusdansi*, 1(9).
- Naquitasia, R., Hatta Fudholi, D., & Iswari, L. (2022). *Analisis Sentimen Berbasis Aspek Pada Wisata Halal Dengan Metode Deep Learning* (Vol. 16, Number 2). <https://ejurnal.teknokrat.ac.id/index.php/teknoinfo/index>
- Nitami, M. T., & Februariyanti, H. (2022). Analisis Sentimen Ulasan Ekspedisi J&T Express Menggunakan Algoritma Naive Bayes. *Jurnal Manajemen Informatika Dan Sistem Informasi*, 5(1), 20–29.

- Novanza, A. R., Pratiwi, O. N., & Hamami, F. (2025). Klasifikasi Multi-Label Pada Soal Berdasarkan Kategori Topik Menggunakan Metode Support Vector Machine. *EProceedings of Engineering*, 12(1).
- Radiena, G., & Nugroho, A. (2023). Analisis Sentimen Berbasis Aspek Pada Ulasan Aplikasi Kai Access Menggunakan Metode Support Vector Machine. In *Jurnal Pendidikan Teknologi Informasi (JUKANTI)* (Number 1).
- Rama Hadi Suryanto, M., & Wahyu Utomo, D. (2024). *Pembelajaran Ensemble Untuk Klasifikasi Ulasan Pelanggan E-commerce Menggunakan Teknik Boosting*. 15(02). <https://doi.org/10.35970/infotekmesin.v15i2.2314>
- Rifa'i, A., Sujaini, H., & Prawira, D. (2021). Sentiment Analysis Objek Wisata Kalimantan Barat Pada Google Maps Menggunakan Metode Naive Bayes. *JEPIN (Jurnal Edukasi Dan Penelitian Informatika)*, 7(3), 400–407.
- Salsabillah, D. F., Ratnawati, D. E., & Setiawan, N. Y. (2024a). Analisis Sentimen Ulasan Rumah Makan Menggunakan Perbandingan Algoritma *Support Vector Machine* dengan *Naive bayes* (Studi Kasus: Ayam Goreng Nelongso Cabang Singosari, Malang). *Jurnal Teknologi Informasi Dan Ilmu Komputer*, 11(1), 107–116. <https://doi.org/10.25126/jtiik.20241117584>
- Salsabillah, D. F., Ratnawati, D. E., & Setiawan, N. Y. (2024b). Analisis Sentimen Ulasan Rumah Makan Menggunakan Perbandingan Algoritma *Support Vector Machine* dengan *Naive bayes* (Studi Kasus: Ayam Goreng Nelongso Cabang Singosari, Malang). *Jurnal Teknologi Informasi Dan Ilmu Komputer*, 11(1), 107–116. <https://doi.org/10.25126/jtiik.20241117584>
- Septiana Rizky, P., Haiban Hirzi, R., Hidayaturrohman, U., Hamzanwadi Selong Jl TGKH Muhammad Zainuddin Abdul Madjid Pancor, U., & Timur, L. (2022). Perbandingan Metode LightGBM dan XGBoost dalam Menangani Data dengan Kelas Tidak Seimbang. In *J Statistika* (Vol. 15, Number 2). www.unipasby.ac.id
- Simplified structure of XGBoost*. (n.d.). Retrieved June 20, 2025, from https://www.researchgate.net/figure/Simplified-structure-of-XGBoost_fig2_348025909
- Sondakh, D. E., Taju, S. W., Tene, M. G., & Pangaila, A. E. T. (2023). Sistem Analisis Sentimen Ulasan Aplikasi Belanja Online Menggunakan Metode Ensemble Learning Sentiment Analysis System for Online Shopping Application Reviews Using Ensemble Learning Method. *Cogito Smart Journal* |, 9(2).
- Tao, J., & Fang, X. (2020). Toward multi-label sentiment analysis: a transfer learning based approach. *Journal of Big Data*, 7(1). <https://doi.org/10.1186/s40537-019-0278-0>
- Winalda, I. T., & Sudarwanto, T. (2022). Pengaruh word of mouth dan kualitas produk terhadap keputusan pembelian di Rumah Makan Bebek Sinjay Bangkalan. *Jurnal Pendidikan Tata Niaga (JPTN)*, 10(1), 1573–1582.
- XGBoost vs LightGBM vs CatBoost Perbandingan Terbaik (2025)*. (n.d.). Retrieved June 20, 2025, from <https://kirim.ai/xgboost-vs-lightgbm-vs-catboost-perbandingan>

Zidny, T. (2024). Analisis Sentimen Ulasan Mie Gacoan Solo Veteran Di Google Maps Menggunakan Algoritma Naive Bayes. In *Analisis Sentimen Ulasan Mie Gacoan Solo Veteran.... ZONasi: Jurnal Sistem Informasi* (Vol. 6, Number 3).